

REMERCIEMENTS

Avant toute chose, je tiens à exprimer ma profonde gratitude envers Dieu, pour la force, la santé et la persévérance qu'Il m'a accordées tout au long de la réalisation de ce travail.

Je tiens ensuite à exprimer ma sincère reconnaissance au Dr Ingénieur RAMASONDRANO Andriamanjaka, Directeur de l'école, qui a également assuré l'encadrement de ce mémoire. Malgré ses nombreuses responsabilités à la tête de l'établissement, il a su m'accorder de son temps précieux, me prodiguer des conseils avisés et m'accompagner avec rigueur et bienveillance tout au long de ce mémoire.

Mes remerciements vont aussi à l'ensemble des enseignants, pour la qualité de l'enseignement dispensé, ainsi qu'aux membres du jury, pour avoir accepté d'évaluer ce travail et pour l'intérêt qu'ils y ont porté.

Enfin, je ne saurais oublier ma famille et mes proches, dont le soutien indéfectible, a été un pilier essentiel. Je remercie également mes amis pour leur présence et leur soutien tout au long de ce mémoire.

À toutes celles et à tous ceux qui, de près ou de loin, ont contribué à la réalisation de ce travail, j'adresse mes sincères remerciements.

RESUME

Table des matières

1	Introduction	1
2	Présentation de l'INSI	2
2.1	Information d'ordre général	2
2.2	Missions et historiques	2
2.3	Organigramme de l'INSI	2
2.4	Domaine de spécialisation	3
2.4.1	Licences professionnelles	4
2.4.2	Masters professionnels	4
2.4.3	Formations professionnelles continues	4
2.4.4	Mobilité internationale et double diplôme	4
2.5	Architectures des formations pédagogiques	4
2.5.1	Relations de l'INSI avec les entreprises et les organismes	5
2.5.2	Partenariat au niveau international	6
2.5.3	Parcours professionnels des diplômés	6
2.5.4	Ressources humaines	7
3	État de l'art et Cadre théorique	8
3.1	Contexte et analyse sectorielle de la rizipisciculture à Madagascar	8
3.2	Fondements théoriques des modèles d'apprentissage et de traitement de données	9
3.2.1	Algorithmes de Machine Learning	9
3.2.2	Analyse Temporelle et Deep Learning	13
3.2.3	Optimisation par GridSearch	14
3.2.4	Mise à l'échelle des données	15
3.3	Approche méthodologique et cartographie des modules	16
4	Méthodologie et préparation des données	16
4.1	Origine et collecte des données	16
4.2	Structure des datasets	17
4.3	Visualisation et analyse	18
4.4	Prétraitement des données	23
4.4.1	Module 1	23
4.4.2	Module 2	24
4.4.3	Module 3	25
4.4.4	Mise à l'échelle	25
4.5	Stratégie d'évaluation et découpage des données	25
4.5.1	Module 1	26
4.5.2	Module 2	26
4.5.3	Module 3	27
5	Mise en œuvre et évaluation des modules	27
5.1	Environnement de développement et outils	27
5.1.1	Matériel et écosystème logiciel	27
5.1.2	Librairies de manipulation et de visualisation de données	27
5.1.3	Écosystème de Machine Learning et optimisation	27
5.1.4	Outils d'analyse temporelle et de Deep Learning	28

LISTE DES ABREVIATIONS, SIGLES ET ACRONYMES

APDRA	: Association Pisciculture et Développement Rural en Afrique
FAO	: Food and Agriculture Organization
IISD	: Institut International du Développement Durable
PADM	: Projet d'Aquaculture Durable à Madagascar

GLOSSAIRE

Liste des tableaux

Tableau 1: Parcours Licence et Master proposés à l'INSI	page 5
Tableau 2: Hyperparamètres – Régression Linéaire	page 9
Tableau 3: Hyperparamètres – Régression Logistique	page 10
Tableau 5: Hyperparamètres – Arbre de Décision	page 12
Tableau 6: Hyperparamètres – Random Forest	page 12
Tableau 7: Hyperparamètres – XGBoost	page 13
Tableau 8: Cartographie des trois modules du système	page 16
Tableau 9: Structure du dataset – Module 1	page 17
Tableau 10: Structure du dataset – Modules 2 et 3	page 18

Table des figures

Figure 1: Organigramme de l'INSI	page 2
Figure 2: Distribution de la variable Densite_Tilapia_Are	page 18
Figure 3: Densité de tilapia selon la hauteur d'eau	page 19
Figure 4: Densité de tilapia selon la température actuelle	page 19
Figure 5: Densité de tilapia selon le niveau d'engrais	page 19
Figure 6: Densité de tilapia selon le type d'irrigation	page 19
Figure 7: Densité de tilapia selon la couleur du sol	page 20
Figure 8: Densité de tilapia selon la texture du sol	page 20
Figure 9: Matrice de corrélation des variables du Module 1	page 20
Figure 10: Distribution de la Turbidité selon la qualité de l'eau	page 21
Figure 11: Distribution de la Température selon la qualité de l'eau	page 21
Figure 12: Distribution du pH selon la qualité de l'eau	page 22
Figure 13: Distribution de l'Oxygène Dissous selon la qualité de l'eau	page 22
Figure 14: Matrice de corrélation entre les composants de l'eau	page 22
Figure 15: Répartition des classes de qualité de l'eau	page 23

1 Introduction

La sécurité alimentaire et la gestion des ressources aquatiques sont des enjeux importants aujourd'hui, car la population mondiale augmente et la pression sur les systèmes agricoles et halieutiques augmente aussi. Dans ce contexte, l'aquaculture devient une solution de plus en plus utilisée en complément de la pêche traditionnelle, dont les stocks naturels diminuent. Le tilapia est l'une des espèces les plus élevées dans le monde, car il s'adapte facilement à différents environnements. À Madagascar, on retrouve cette tendance à travers la rizipisciculture, une pratique qui consiste à associer l'élevage de poissons à la culture du riz dans les mêmes parcelles. Cependant, IISD constate que seulement environ 20 % des rizières qui pourraient accueillir la rizipisciculture à Madagascar sont réellement exploitées à cet effet, ce qui montre qu'il reste une grande marge de progression, notamment freinée par le manque d'outils fiables pour surveiller et anticiper les problèmes de qualité de l'eau.

C'est de ce constat que découle la problématique de ce mémoire : comment analyser la qualité de l'eau et les conditions environnementales d'une parcelle de rizipisciculture afin de protéger, anticiper et optimiser la production de Tilapia ?

Pour répondre à cette problématique, l'objectif général de ce mémoire est de concevoir un système intelligent capable d'analyser les conditions environnementales d'une parcelle rizipiscicole, afin d'aider les exploitants à protéger, anticiper et optimiser leur production de tilapia. Cet objectif se décompose en trois objectifs spécifiques, correspondant aux trois fonctionnalités du système :

D'abord, construire un modèle prédictif capable d'estimer la densité de tilapia atteignable à partir des caractéristiques du sol rizicole, en comparant plusieurs algorithmes de machine learning et en optimisant leurs hyperparamètres par GridSearch.

Ensuite, construire un modèle de classification capable de déterminer si l'état actuel de l'eau est bon ou mauvais pour le tilapia, avec la même démarche de comparaison et d'optimisation.

Enfin, développer un modèle prédictif capable d'estimer l'évolution de la qualité de l'eau dans l'heure qui suit, en combinant une décomposition de série temporelle (STL) et un modèle LSTM, afin de déclencher une alerte en cas de dégradation anticipée.

Pour atteindre ces objectifs, la méthodologie utilisée repose sur une démarche de science des données. Elle comprend la collecte de données environnementales et physico-chimiques (caractéristiques du sol, paramètres de l'eau), leur nettoyage et leur préparation, puis leur exploitation à travers des modèles de machine learning de régression et de classification, évalués et optimisés par validation croisée et GridSearch. Pour la partie prédiction temporelle, une décomposition STL est appliquée avant d'entraîner un modèle LSTM. Les outils utilisés sont principalement issus de l'écosystème Python, avec les bibliothèques scikit-learn, statsmodels et TensorFlow/Keras.

Ce projet présente un intérêt sur plusieurs plans. Sur le plan pédagogique, il permet de mettre en pratique, sur un cas concret, l'ensemble des étapes d'un projet de science des données, de la collecte des données jusqu'au déploiement de modèles prédictifs. Sur le plan professionnel, il s'inscrit dans la dynamique de digitalisation de l'agriculture soutenue par l'État malagasy. Sur le plan sociétal, il vise à donner aux exploitants rizipisciculteurs un outil simple pour anticiper les problèmes et protéger leur production.

Ce mémoire est organisé en plusieurs chapitres. Le premier chapitre présente un état de l'art et le cadre théorique du sujet. Le deuxième chapitre présente la méthodologie du projet, avec la description des données, leur préparation et l'architecture générale du système. Le troisième chapitre présente la mise en œuvre des trois fonctionnalités et l'évaluation comparative des modèles obtenus. Le dernier chapitre discute des résultats ainsi que des pistes d'amélioration pour le système.

2 Présentation de l'INSI

2.1 Information d'ordre général

INSI (Institut National Supérieur d'Informatique) est un institut universitaire situé à Antananarivo, spécialisé dans le domaine de l'informatique. Il accueille principalement des bacheliers ayant choisi cette filière, mais reste également ouvert à toute personne manifestant un intérêt particulier pour les métiers du numérique, à travers son centre de formation professionnelle.

L'établissement a été fondé le 17 août 2021 et son siège se trouve à Ankazotokana Ambanidia, Lot VF 32 Ter.

Pour tout renseignement, vous pouvez nous contacter par email à contact@insi.mg ou visiter notre site web : www.insi.mg.

INSI University bénéficie du soutien d'entreprises partenaires, dont Ilo Madagascar SARLU et Data Pulse Center, qui sont également à l'origine de sa création.

2.2 Missions et historiques

INSI University a été fondée le 17 août 2021 à Antananarivo, dans un contexte marqué par une forte demande de compétences dans le domaine de l'informatique et des technologies numériques.

Créé à l'initiative de Ilo Madagascar SARLU et Data Pulse Center, l'Institut a vu le jour avec pour ambition de former une nouvelle génération de professionnels qualifiés, capables de répondre aux besoins du marché local et international.

Depuis sa création, INSI ne cesse d'évoluer en adaptant ses formations aux enjeux technologiques actuels, tout en favorisant un apprentissage pratique, orienté vers les réalités du monde professionnel.

La mission principale de l'INSI est de former des experts compétents, éthiques et innovants dans le domaine de l'informatique, capables de contribuer activement au développement économique et numérique de Madagascar.

2.3 Organigramme de l'INSI




FIGURE 1 – Organigramme de l'INSI
Source : INSI, 2025

L'organigramme de l'INSI, en partenariat avec le Collège de Paris, est structuré autour d'une direction générale incarnée par le Président Directeur Général. Ce dernier assure la coordination de trois pôles principaux : la **Direction Administrative et Financière**, la **Direction des Études**, et le **Service des Relations Internationales et Mobilités**.

Le **Président Directeur Général** assure la direction stratégique de l'institut. Il supervise l'ensemble des activités pédagogiques, administratives et de développement. Il veille à la qualité de l'enseignement, à la bonne gestion des ressources humaines et matérielles, et représente l'établissement auprès des partenaires et autorités.

La **Direction Administrative et Financière** est chargée de la gestion des affaires internes, notamment à travers deux services essentiels :

- le **Service des scolarités**, qui s'occupe des dossiers étudiants, inscriptions et suivi académique,
- les **Services supports et stratégiques**, qui assurent un appui logistique, administratif et technologique à l'ensemble de l'institut.

Le **pôle des Relations Internationales et Mobilités** gère les échanges académiques avec l'étranger ainsi que les projets de mobilité étudiante ou enseignante.

La **Direction des Études** supervise quant à elle l'ensemble des programmes pédagogiques et le corps enseignant. Elle travaille en étroite collaboration avec un **Responsable Parcours**, qui coordonne les différentes spécialisations proposées. Cette direction intègre également une **cellule Formation professionnelle et certification**, en charge des dispositifs de validation des compétences, des certifications professionnelles et des parcours de formation continue. Elle comprend aussi le **Département alternance et emploi**, responsable du suivi des étudiants en contrat d'alternance, des stages professionnels, et de l'insertion professionnelle.

Sous la responsabilité du **Responsable Parcours**, plusieurs responsables pédagogiques gèrent les différentes filières de formation :

- le **parcours tronc commun**, qui regroupe les matières fondamentales partagées par tous les étudiants en début de cycle,
- le **parcours ARSB & IC**,
- le **parcours GL & MSI**,
- le **parcours IAD & I2AD**.

D'autres structures, bien que non représentées sur cet organigramme, contribuent également de manière significative à la mission de l'INSI :

- Le **Conseil de l'École**, regroupant des membres de l'équipe pédagogique et administrative. Il joue un rôle consultatif ou décisionnel sur les questions académiques : validation des programmes, suivi des résultats, discipline, méthodologie, etc.
- Le **Responsable de la formation en ligne**, qui conçoit et supervise les dispositifs d'apprentissage à distance. Il s'assure que les contenus en ligne sont accessibles, interactifs et conformes aux standards pédagogiques, tout en accompagnant enseignants et étudiants dans leur utilisation.
- L'**Association et les clubs étudiants**, qui encadrent et soutiennent les initiatives étudiantes, les clubs thématiques (informatique, innovation, sport, culture, etc.), et les événements organisés dans le cadre de la vie étudiante. Cela favorise l'engagement, le développement personnel et les compétences transversales des étudiants.

Cette structure témoigne d'une organisation à la fois pédagogique, administrative et tournée vers l'international et l'employabilité, assurant une formation complète et professionnalisante aux étudiants.

2.4 Domaine de spécialisation

INSI University propose des parcours académiques professionnalisants dans le domaine de l'informatique et des technologies numériques, articulés autour de licences professionnelles, de masters spécialisés, de formations professionnelles continues et d'opportunités de mobilité internationale.

2.4.1 Licences professionnelles

Les programmes de licence offrent une formation de base solide, axée sur la pratique, et préparant à une insertion rapide dans le monde professionnel :

- **GL (Génie Logiciel)** : Conception, développement et maintenance d'applications logicielles.
- **ARSB (Administration Réseaux et Systèmes et Base de données)** : Gestion d'infrastructures informatiques, réseaux, serveurs et systèmes.
- **IAD (Intelligence Artificielle et Data Science)** : Introduction aux algorithmes d'IA, au traitement de données et à l'apprentissage automatique.

2.4.2 Masters professionnels

Les masters permettent d'approfondir les compétences techniques et managériales, en lien étroit avec les évolutions du secteur :

- **MSI (Management des Systèmes d'Information)** : Pilotage de projets numériques, gouvernance des SI.
- **IC (Infrastructures et Cybersécurité)** : Sécurisation des systèmes, audit, réseaux avancés.
- **I2AD (Intelligence Artificielle, Analyse de Données et Automatisation)** : Applications avancées de l'IA, automatisation des processus et science des données.

2.4.3 Formations professionnelles continues

INSI University propose également des formations professionnelles continues, spécifiquement conçues pour les professionnels déjà en poste souhaitant approfondir leurs compétences ou se spécialiser dans l'un des domaines proposés.

Ces formations sont adaptées aux contraintes des professionnels (horaires flexibles, modules pratiques) et visent à renforcer leur employabilité ou à accompagner leur évolution de carrière.

2.4.4 Mobilité internationale et double diplôme

Dans une optique d'ouverture et de reconnaissance internationale, INSI propose à ses étudiants des opportunités de mobilité académique et de double diplôme, à partir de la deuxième année (L2) :

- **Format hybride** : 6 mois de formation à Madagascar + 6 mois à l'étranger selon le parcours choisi.
- **Double diplôme en L3 ou M2** : En partenariat avec des institutions internationales telles que :
 - Collège de Paris (France)
 - Keyce Informatique (France)
 - Eskills (Québec, Canada)

Conditions d'éligibilité

- Niveau DALF C1 en français pour la mobilité vers des pays francophones.
- Niveau B2 ou C1 en anglais pour les destinations anglophones.

2.5 Architectures des formations pédagogiques

Le recrutement des étudiants à l'INSI s'effectue exclusivement par sélection de dossiers pour l'entrée en première année de Licence (L1), et par voie de concours pour l'admission en Master 1.

Au sein de l'INSI, une seule mention est proposée : **Informatique**, déclinée en trois parcours distincts aux niveaux Licence et Master.

Licence	Master
Génie Logiciel (GL)	Management des Systèmes d'Information (MSI)
Administration Réseaux, Systèmes et Bases de données (ARSB)	Infrastructures et Cybersécurités (IC)
Intelligence Artificielle et Data Science (IAD) Automatisation (I2AD)	Intelligence Artificielle, Analyse de Données et

TABLE 1 – Parcours Licence et Master proposés à l'INSI
Source : INSI, 2025

L'architecture des études à trois niveaux conformément au système LMD (Licence Master et Doctorat) permet les comparaisons et les équivalences académiques des diplômes au niveau international.

L = Licence (Bac + 3) = L1, L2, L3 = 6 semestres S1 à S6

M = Master (Bac + 5) = M1, M2 = 4 semestres S7 à S10

Le diplôme de licence est obtenu en 3 années des études après Baccalauréat. Et le diplôme de Master est obtenu en 2 ans après obtenu du diplôme de LICENCE.

Le MASTER PROFESSIONNEL est un diplôme destiné à la recherche emploi au terme des études.

Spécificités pédagogiques

- École d'alternance dès la L2 S4
Alternance cours/entreprise pour une meilleure insertion
- Écoles connectées & e-learning
Plateforme numérique de formation, cloud intégré, Google Workspace
Cours accessibles en ligne selon les parcours
- Pédagogie active & par projets
Hackathons, soutenances exposées, projets réels en entreprise

2.5.1 Relations de l'INSI avec les entreprises et les organismes

L'Institut National Supérieur en Informatique (INSI) entretient des liens étroits avec le monde professionnel. L'INSI collabore activement avec de nombreux organismes publics, semi-publics et privés, tant au niveau national qu'international. Cette collaboration se traduit concrètement par l'organisation régulière de stages obligatoires pour les étudiants, favorisant leur immersion professionnelle et leur employabilité.

Parmi les entreprises et institutions partenaires accueillant nos étudiants en stage chaque année :

- Data Pulse Center
- RELIA Consulting
- Code Talent
- Bocasay
- Minimad
- Smartone AI
- NOVITY
- Eclosia Madagascar
- VISEO Groupe
- Océane Trade
- ACCES Banque

En plus des stages, l'INSI organise régulièrement des visites pédagogiques, des rencontres métiers et des projets collaboratifs avec plusieurs entreprises du secteur technologique et numérique. Ces activités

permettent aux étudiants de mieux comprendre les réalités du terrain, d'échanger avec des professionnels et de s'ouvrir à l'environnement entrepreneurial.

Parmi les entreprises ayant accueilli ces initiatives :

- NOVITY
- YAS Madagascar
- Smartone AI
- Eclosia Madagascar
- et d'autres acteurs majeurs du numérique à Madagascar

Cette dynamique de partenariat permanent constitue un pilier de la pédagogie à l'INSI, en lien avec son objectif de former des professionnels compétents, opérationnels et ancrés dans les besoins du marché.

2.5.2 Partenariat au niveau international

L'INSI s'est inscrit dans une dynamique d'ouverture à l'international grâce à son partenaire fondateur, ILO Madagascar, représentant de l'Organisation Internationale du Travail. Cette orientation se renforce aujourd'hui à travers des partenariats stratégiques avec des institutions académiques et des entreprises internationales, permettant à l'Institut de proposer une formation alignée sur les standards mondiaux.

L'INSI bénéficie actuellement de programmes de co-diplomation et de double diplôme en collaboration avec plusieurs établissements internationaux de renom :

- Collège de Paris International
- Keyce Informatique (France)
- Eskills Academy (Québec, Canada)
- École Supérieure Polytechnique d'Antsiranana (ESPA) – pour une synergie régionale renforcée

Par ailleurs, à travers les stages annuels et projets pédagogiques, l'INSI collabore également avec des entreprises à dimension régionale ou mondiale :

- VISEO Groupe
- Eclosia Madagascar (Groupe mauricien)
- Smartone AI
- NOVITY

2.5.3 Parcours professionnels des diplômés

Les diplômés de la Licence en Informatique de l'INSI disposent d'un socle solide de compétences en programmation, systèmes, réseaux, bases de données et développement logiciel. Cette polyvalence leur permet d'intégrer directement le marché du travail ou de poursuivre en Master. À ce niveau, ils peuvent exercer en tant que :

- Technicien système et réseau
- Développeur web / mobile (front-end ou back-end)
- Administrateur systèmes junior
- Technicien support IT
- Intégrateur / testeur logiciel
- Assistant en sécurité informatique
- Assistant en projets d'IA ou de data (selon profil)

Les stages annuels en entreprise leur offrent une première expérience professionnelle valorisante dans des structures variées : entreprises technologiques, banques, administrations, startups, ONG, etc.

La formation de Master proposée à l'INSI, grâce à ses parcours spécialisés, forme des professionnels capables d'intervenir sur des projets complexes, innovants et à dimension stratégique. Les débouchés varient selon la spécialisation choisie :

Parcours Ingénierie logicielle, réseaux et systèmes :

- Ingénieur en développement logiciel / full-stack
- Architecte logiciel
- Ingénieur systèmes et réseaux
- Administrateur cloud / DevOps
- Chef de projet informatique

Parcours Cybersécurité :

- Expert en sécurité des systèmes d'information
- Analyste SOC / CERT
- Auditeur en cybersécurité
- Responsable de la sécurité IT (RSSI)

Parcours Intelligence Artificielle et Data :

- Data Scientist
- Data Analyst
- Ingénieur en Intelligence Artificielle
- Machine Learning Engineer
- Développeur d'applications intelligentes
- Consultant en IA
- Spécialiste en traitement automatique du langage naturel (TALN)
- Spécialiste en vision par ordinateur (Computer Vision)

Grâce aux partenariats internationaux et aux projets en entreprise, les diplômés du Master peuvent également prétendre à des postes dans des structures multinationales, ou poursuivre une carrière académique et de recherche (doctorat, enseignement supérieur).

2.5.4 Ressources humaines

L'INSI s'appuie sur une équipe pédagogique et administrative compétente, dynamique et engagée dans la réussite de ses étudiants. Ses ressources humaines se répartissent comme suit :

- Président Directeur de l'INSI : Dr RAMASONDRANO Andriamanjaka
- Responsable parcours ARSB & IC : Mr RATIANARISON Hery Mampionona
- Responsable parcours tronc commun : Dr RAKOTONDRAMANANA R, Sitraka
- Responsable parcours GL & MSI : Mr ANDRIAMIADANA TANTELY ANTOINE
- Responsable parcours IAD & I2AD : par intérim PDG
- Nombres d'enseignants : 40
- Nombres des personnels administratives : 04
- Personnels d'appui : 6

3 État de l’art et Cadre théorique

3.1 Contexte et analyse sectorielle de la rizipisciculture à Madagascar

Le tilapia est l’une des espèces les plus élevées dans le monde, car il s’adapte facilement à différents environnements. La rizipisciculture est une pratique qui consiste à associer l’élevage de poissons à la culture du riz dans les mêmes parcelles. Cette technique est utilisée depuis le milieu du XX^{ème} siècle et présente un avantage simple : le riz protège les poissons et leur sert de nourriture, tandis que les poissons fertilisent naturellement les rizières. Des études réalisées sur les Hautes-Terres malgaches par l’APDRA montrent que l’ajout de poissons dans une rizière peut augmenter le rendement du riz de 10 % à 20 %, sans réduire la surface cultivable.

Pour situer ce sujet, plusieurs aspects peuvent être analysés. Du côté politique, l’État malgache met en place une stratégie de modernisation numérique de l’agriculture. La Stratégie Nationale de Transformation Digitale de l’Agriculture (2024-2028), portée par le Ministère de l’Agriculture et de la Souveraineté Alimentaire avec le Ministère du Développement Numérique, prévoit la mise en place d’une Infrastructure Publique Numérique Agricole. Cette infrastructure doit relier les différents acteurs du secteur (institutions publiques, instituts de recherche comme le FOFIFA, organisations de producteurs) et garantir que les données agricoles restent maîtrisées par le pays. Cette stratégie est aussi soutenue par des partenaires comme la Banque mondiale et la FAO.

Du côté économique, la rizipisciculture permet aux paysans d’obtenir deux produits (riz et poisson) sur la même parcelle, pour un coût d’installation réduit, ce qui en fait une source de revenu supplémentaire intéressante.

Du côté socioculturel, la rizipisciculture est une pratique ancienne à Madagascar utilisée par les paysans à travers le pays. Le tilapia est bien connu et apprécié par les consommateurs locaux, notamment parce qu’il grandit vite. Pourtant, la grande majorité des riziculteurs malgaches cultivent uniquement le riz et ne pratiquent pas l’élevage de tilapia dans leurs parcelles, souvent par manque de connaissance de la pratique ou par manque d’outils pour la mener sereinement.

Du côté technologique, l’usage de capteurs et de modèles de machine learning pour surveiller la qualité de l’eau se développe déjà dans l’aquaculture intensive à l’échelle mondiale. Mais à Madagascar, ces outils sont encore peu utilisés dans la rizipisciculture, où le suivi de l’eau se fait encore principalement à l’œil ou de façon manuelle.

Du côté environnemental, la rizipisciculture est considérée comme un système de production qui a un faible impact écologique. IISD affirme une réduction des émissions de gaz à effet de serre d’environ 0,81 kg de CO₂ équivalent par kilogramme de riz produit, par rapport à des systèmes de pisciculture plus intensifs. Mais la qualité de l’eau dans une parcelle rizipiscicole peut varier rapidement (température, oxygène, nutriments), et si ces variations ne sont pas surveillées et anticipées, elles peuvent mettre en danger les poissons élevés.

Enfin, du côté légal, le développement de l’aquaculture à Madagascar est encadré depuis le milieu des années 2000 par une stratégie nationale de développement durable de l’aquaculture, mise en place par le Ministère chargé de la Pêche avec la FAO. Plus récemment, la feuille de route de l’Infrastructure Publique Numérique Agricole insiste sur la gouvernance et la maîtrise des données du secteur.

Face à ces défis environnementaux et techniques, l’application de l’intelligence artificielle offre une opportunité de suivi automatisé. La section suivante présente les fondements théoriques des algorithmes

retenus pour cette étude.

3.2 Fondements théoriques des modèles d'apprentissage et de traitement de données

Après avoir situé le contexte sectoriel de la rizipisciculture, il est nécessaire de poser les bases théoriques des outils qui seront utilisés dans ce mémoire. Cette section présente d'abord les algorithmes de machine learning mobilisés pour les tâches de régression et de classification, ainsi que la méthode d'optimisation retenue, puis les techniques d'analyse temporelle et de deep learning utilisées pour la prédiction à court terme de la qualité de l'eau.

3.2.1 Algorithmes de Machine Learning

Régression Linéaire

La régression linéaire est le modèle le plus simple pour prédire une valeur numérique continue à partir d'un ensemble de variables explicatives. Le modèle suppose qu'il existe une relation linéaire entre les variables d'entrée ($x_1, x_2, \dots, x_n$) et la variable de sortie (y). Pour une observation donnée, la prédiction ($\hat{y}$) s'écrit :

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

où :

$\hat{y}$ est la valeur prédite

β_0 est l'ordonnée à l'origine (biais), c'est-à-dire la valeur prédite lorsque toutes les variables d'entrée sont nulles

$\beta_1, \dots, \beta_n$ sont les coefficients associés à chaque variable, indiquant le poids et le sens de l'influence de chaque caractéristique du sol sur la densité prédite.

Hyperparamètre	Interprétation
fit_intercept	Indique si le modèle doit calculer l'ordonnée à l'origine β_0 , ou la fixer à zéro. True : le biais est estimé normalement. False : le modèle est contraint à passer par l'origine, ce qui n'est pertinent que si l'on sait a priori que $y = 0$ lorsque toutes les variables sont nulles.
alpha (Ridge/Lasso)	Contrôle l'intensité de la pénalisation appliquée aux coefficients β_i pour limiter le surapprentissage : plus α est élevé, plus les coefficients sont contraints vers de petites valeurs.

TABLE 2 – Hyperparamètres – Régression Linéaire

Régression Logistique

Contrairement à la régression linéaire, la régression logistique n'est pas utilisée pour prédire une valeur continue, mais pour résoudre un problème de classification.

Le problème d'une régression linéaire directe pour cette tâche est que $\hat{y} = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$ peut prendre n'importe quelle valeur réelle, positive ou négative, ce qui n'a pas de sens pour représenter une classe. La régression logistique résout ce problème en appliquant une fonction supplémentaire à la combinaison linéaire des variables : la fonction sigmoïde, notée σ , qui transforme n'importe quelle valeur réelle en une valeur comprise entre 0 et 1, interprétable comme une probabilité :

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

En posant $z = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$, la probabilité que l'observation appartienne à la classe positive s'écrit :

$$P(y = 1 | x) = \sigma(z) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}$$

Hyperparamètre	Interprétation
C	Inverse de la force de régularisation : une valeur faible impose une forte régularisation, une valeur élevée laisse le modèle s'ajuster plus librement aux données.
penalty	Type de régularisation appliquée aux coefficients. l2 : pénalise le carré des coefficients, les réduit sans les annuler l1 : pénalise leur valeur absolue, ce qui peut annuler certains coefficients (sélection de variables) elasticnet : combinaison pondérée de l1 et l2 none : aucune régularisation appliquée.
solver	Algorithme d'optimisation utilisé pour minimiser la fonction de coût logistique. lbfgs : méthode quasi-Newton, adaptée aux jeux de données de taille moyenne avec pénalité l2 liblinear : adapté aux petits jeux de données et compatible avec la pénalité l1 saga : adapté aux grands jeux de données et compatible avec l1, l2 et elasticnet newton-cg et sag : variantes alternatives d'optimisation, plus rapides sur de grands volumes de données avec pénalité l2.

TABLE 3: Hyperparamètres – Régression Logistique

Machines à Vecteurs de Support (SVM)

Les Machines à Vecteurs de Support cherchent à séparer les données en deux classes en traçant un hyperplan (une droite, ou son équivalent en plusieurs dimensions) entre elles. Parmi tous les hyperplans possibles, le SVM choisit celui qui maximise la marge, c'est-à-dire la distance entre l'hyperplan et les points les plus proches de chaque classe, appelés vecteurs de support :

$$f(x) = \mathbf{w}^T x + b$$

où $\mathbf{w}$ et b définissent la position et l'orientation de l'hyperplan. Un hyperplan qui maximise cette marge généralise en principe mieux sur de nouvelles données. Lorsque les données ne sont pas séparables par une simple droite, le SVM utilise l'astuce du noyau (kernel trick), qui permet de les séparer comme si elles avaient été projetées dans un espace de dimension supérieure, sans avoir à calculer cette projection. Le SVM se décline en deux variantes : le SVC pour la classification et le SVR pour la régression.

Hyperparamètre	Interprétation
C	Contrôle le compromis entre la maximisation de la marge et la tolérance aux erreurs de classification.

kernel	Type de noyau utilisé pour séparer les données. linear : suppose une séparation linéaire des données, sans transformation poly : introduit des combinaisons polynomiales des variables, utile pour des frontières courbes simples rbf (par défaut) : noyau gaussien, adapté à des frontières de décision complexes et non linéaires.
gamma	Dans le noyau RBF, contrôle l'influence de chaque point d'entraînement sur la frontière de décision.
epsilon (SVR)	Définit la largeur du tube de tolérance autour des prédictions, à l'intérieur duquel aucune pénalité n'est appliquée.

Arbre de Décision

L'Arbre de Décision construit une succession de règles de décision simples sous forme d'arbre. À chaque nœud, une question binaire est posée sur une variable (par exemple : $x_j > s$?), ce qui dirige l'observation vers l'enfant de gauche ou de droite, jusqu'à atteindre une feuille contenant la prédiction finale. Le découpage à chaque nœud est choisi selon un critère d'homogénéité, mesuré principalement de deux façons en classification :

L'impureté de Gini, qui mesure la probabilité de mal classer une observation si elle était étiquetée aléatoirement selon la distribution des classes du nœud :

$$G = 1 - \sum_{k=1}^K p_k^2$$

L'Entropie, issue de la théorie de l'information, qui mesure le désordre ou l'incertitude présente dans le nœud :

$$H = - \sum_{k=1}^K p_k \log_2(p_k)$$

où p_k est la proportion d'observations de la classe k dans le nœud considéré. Dans les deux cas, une valeur de 0 correspond à un nœud parfaitement homogène (une seule classe présente), tandis que la valeur est maximale lorsque les classes sont réparties de façon égale dans le nœud.

Hyperparamètre	Interprétation
max_depth	Profondeur maximale de l'arbre : une valeur élevée capture des relations plus complexes mais augmente le risque de surapprentissage.
min_samples_split	Nombre minimal d'observations requises dans un nœud pour autoriser un nouveau découpage.
min_samples_leaf	Nombre minimal d'observations requises dans une feuille.

criterion	Critère utilisé pour évaluer la qualité d'un découpage. En classification : gini mesure la probabilité de mal classer une observation tirée au hasard selon la distribution du nœud entropy mesure le désordre des classes présentes, avec une pénalisation légèrement plus forte des nœuds très mélangés. En régression : squared_error (erreur quadratique) est le critère standard absolute_error est moins sensible aux valeurs extrêmes friedman_mse est une variante de l'erreur quadratique optimisée pour les découpages successifs.
-----------	---

TABLE 5: Hyperparamètres – Arbre de Décision

Random Forest

La Random Forest combine un grand nombre d'arbres de décision entraînés sur des échantillons différents des données (tirés aléatoirement avec remise, ou Bagging), et sur un sous-ensemble aléatoire des variables à chaque nœud. Cette double source d'aléa décorrèle les arbres entre eux et réduit la variance globale du modèle. Les prédictions sont ensuite combinées différemment selon la tâche :

$$\hat{y} = \text{mode}(\hat{y}^{(1)}, \dots, \hat{y}^{(T)}) \quad (\text{classification, vote majoritaire})$$

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T \hat{y}^{(t)} \quad (\text{régression, moyenne des arbres})$$

Hyperparamètre	Interprétation
n_estimators	Nombre d'arbres constituant la forêt : plus il y en a, plus la variance du modèle est réduite, au prix d'un temps de calcul plus long.
max_depth	Profondeur maximale de chaque arbre de la forêt.
max_features	Nombre de variables tirées aléatoirement à considérer à chaque nœud. sqrt : considère la racine carrée du nombre total de variables (valeur courante en classification) log2 : considère le logarithme en base 2 du nombre total de variables, un choix plus restrictif None : considère l'ensemble des variables à chaque nœud, ce qui réduit la décorrélation entre les arbres.
min_samples_leaf	Nombre minimal d'observations requises dans une feuille de chaque arbre.

TABLE 6: Hyperparamètres – Random Forest

XGBoost (Extreme Gradient Boosting)

XGBoost est également un algorithme basé sur des arbres de décision, mais il repose sur un principe différent du Bagging : le Boosting. Plutôt que d'entraîner les arbres indépendamment les uns des autres, XGBoost les construit de manière séquentielle, chaque nouvel arbre étant entraîné pour corriger les

erreurs commises par l'ensemble des arbres précédents. La prédiction finale est la somme pondérée des prédictions de tous les arbres construits :

$$\hat{y} = \sum_{t=1}^T f_t(x)$$

où chaque f_t est un arbre de décision entraîné à corriger l'erreur résiduelle laissée par les arbres $f_1, \dots, f_{t-1}$. Ce fonctionnement séquentiel et cette correction intégrée expliquent pourquoi XGBoost obtient souvent de meilleures performances que le Bagging, aussi bien pour des tâches de régression (la sortie $\hat{y}$ est directement une valeur continue) que pour des tâches de classification (la somme des arbres est passée dans une fonction sigmoïde, comme pour la régression logistique, afin d'obtenir une probabilité de classe), au prix d'un temps d'entraînement plus long et d'un réglage plus sensible de ses hyperparamètres.

Hyperparamètre	Interprétation
n_estimators	Nombre d'arbres construits séquentiellement lors du Boosting.
learning_rate	Poids appliqué à la contribution de chaque nouvel arbre : une valeur faible ralentit l'apprentissage mais le rend plus stable.
max_depth	Profondeur maximale de chaque arbre, contrôlant la complexité des corrections apportées à chaque étape.
subsample	Proportion des données utilisées pour entraîner chaque arbre, introduisant de l'aléa pour limiter le surapprentissage.
booster	Type de modèle utilisé à chaque étape du Boosting. gbtree (par défaut) : utilise des arbres de décision comme apprenants faibles gblinear : utilise des fonctions linéaires à la place des arbres dart : variante de gbtree qui ignore aléatoirement certains arbres à chaque étape pour limiter le surapprentissage.
reg_lambda / reg_alpha	Termes de régularisation (L2 et L1) pénalisant la complexité des arbres, correspondant au terme $\Omega(f_t)$ de la fonction de coût.

TABLE 7: Hyperparamètres – XGBoost

3.2.2 Analyse Temporelle et Deep Learning

Décomposition STL

La décomposition STL (Seasonal-Trend decomposition using Loess) est une méthode qui permet de décomposer une série temporelle en trois composantes distinctes : la tendance, la saisonnalité et le résidu. Une série temporelle Y_t s'écrit ainsi :

$$Y_t = T_t + S_t + R_t$$

où T_t est la tendance (évolution générale de la série sur le long terme), S_t la composante saisonnière (variations qui se répètent à intervalles réguliers, comme un cycle jour/nuit) et R_t le résidu, c'est-à-dire les fluctuations restantes non expliquées par les deux premières composantes.

La méthode Loess

Loess (Locally Estimated Scatterplot Smoothing) est une méthode de lissage qui estime une courbe régulière à partir de données bruitées, sans supposer de forme mathématique globale. Pour estimer la

valeur lissée en un point x_0 , seules les observations voisines sont utilisées, chacune pondérée selon sa proximité, généralement via une fonction tricube :

$$w_i = \left(1 - \left|\frac{x_i - x_0}{d}\right|^3\right)^3$$

où d est la distance au point voisin le plus éloigné inclus dans le voisinage considéré. Plus une observation x_i est proche de x_0 , plus son poids w_i est élevé. Une régression pondérée est ensuite ajustée sur ce voisinage, en minimisant l'erreur quadratique pondérée :

$$\min_{\beta} \sum_i w_i (y_i - \beta_0 - \beta_1 x_i)^2$$

et seule sa valeur en x_0 est retenue comme estimation lissée. Ce calcul est répété en glissant le voisinage le long de la série, ce qui produit une courbe qui s'adapte localement aux données.

Dans la décomposition STL, Loess est appliqué successivement : d'abord pour estimer la tendance T_t (variations lentes), puis pour extraire la saisonnalité S_t à partir des données privées de cette tendance, le résidu R_t étant ce qui reste après soustraction des deux composantes.

Réseaux LSTM

Les modèles de machine learning classiques (régression, SVM, arbres de décision) traitent chaque observation de manière indépendante et ne conservent aucune mémoire des observations précédentes. Cette limite les rend peu adaptés aux données séquentielles, comme une série temporelle, où la valeur à un instant donné dépend fortement des valeurs passées.

Les réseaux de neurones récurrents (RNN) ont été conçus pour ce type de données : à chaque instant t , ils combinent l'entrée courante avec une information héritée de l'étape précédente, ce qui leur permet de propager un contexte d'une étape à l'autre. Cependant, sur une séquence longue, cette information a tendance à s'atténuer au fil des étapes, jusqu'à disparaître presque complètement. C'est le problème de la disparition du gradient (vanishing gradient), qui empêche le RNN classique de retenir une information sur de longues séquences.

Les réseaux LSTM (Long Short-Term Memory) ont été conçus pour résoudre ce problème. L'idée centrale est d'ajouter une mémoire à long terme, appelée état de la cellule, qui circule d'une étape à l'autre en étant peu modifiée, ce qui lui permet de conserver une information sur de longues séquences sans qu'elle ne s'efface. L'accès à cette mémoire est contrôlé par trois portes (gates), qui décident respectivement :

- la **porte d'oubli**, quelle partie de la mémoire passée doit être conservée ou supprimée.
- la **porte d'entrée**, quelle nouvelle information, apportée par l'observation courante, doit être ajoutée à cette mémoire.
- la **porte de sortie**, quelle partie de cette mémoire doit être transmise comme résultat à l'instant courant, et servir de base pour l'étape suivante.

Chaque porte est une petite couche de neurones qui produit une valeur entre 0 et 1, agissant comme un filtre : une valeur proche de 0 bloque l'information, une valeur proche de 1 la laisse passer. Grâce à ce mécanisme, la cellule LSTM peut choisir de garder une information pertinente sur de nombreuses étapes, ou de l'oublier rapidement si elle ne l'est plus, ce qui permet au réseau de capter des dépendances temporelles aussi bien courtes que longues, sans souffrir de la disparition du gradient qui limite les RNN classiques.

3.2.3 Optimisation par GridSearch

Il faut distinguer les paramètres d'un modèle, qui sont appris automatiquement pendant l'entraînement (par exemple les coefficients β_i d'une régression, ou la structure des arbres d'une Random Forest), des

hyperparamètres, qui sont fixés avant l'entraînement et qui contrôlent le comportement général du modèle (par exemple le nombre d'arbres ou leur profondeur maximale, le paramètre de régularisation C d'un SVM, ou le taux d'apprentissage de XGBoost).

Le choix de ces hyperparamètres influence fortement la performance d'un modèle, mais il n'existe pas de formule directe pour les déterminer : ils doivent être testés empiriquement. Le GridSearch (recherche par grille) consiste à définir, pour chaque hyperparamètre, un ensemble de valeurs candidates, puis à tester méthodiquement toutes les combinaisons possibles entre ces valeurs.

Pour évaluer chaque combinaison de façon fiable, le GridSearch est combiné à une validation croisée (cross-validation). Cette technique divise les données d'entraînement en k sous-ensembles (folds) de taille égale ; le modèle est entraîné k fois, en utilisant à chaque fois $k - 1$ folds pour l'entraînement et le fold restant pour l'évaluation, puis les k scores obtenus sont moyennés :

$$\text{Score}_{CV} = \frac{1}{k} \sum_{i=1}^k \text{Score}_i$$

La combinaison d'hyperparamètres obtenant le meilleur score moyen en validation croisée est retenue comme configuration finale du modèle. Cette démarche, plus coûteuse en temps de calcul qu'un simple entraînement, permet d'éviter de choisir des hyperparamètres qui donneraient de bons résultats sur un seul découpage des données par hasard, mais qui généraliseraient mal.

3.2.4 Mise à l'échelle des données

Avant d'entraîner certains modèles, les variables numériques doivent souvent être ramenées sur une échelle comparable. En effet, des modèles comme la Régression Linéaire, la Régression Logistique ou le SVM sont sensibles à l'amplitude des variables, car ils reposent sur des combinaisons linéaires ou des calculs de distance directement influencés par cette amplitude : une variable dont les valeurs sont beaucoup plus grandes que les autres risquerait de dominer artificiellement l'apprentissage du modèle, indépendamment de sa réelle importance explicative. Deux techniques principales permettent de corriger ce problème.

Standardisation (Z-score)

La standardisation transforme chaque variable de façon à obtenir une moyenne nulle et un écart-type unitaire :

$$x' = \frac{x - \mu}{\sigma}$$

où μ et σ sont respectivement la moyenne et l'écart-type de la variable. Cette technique conserve la forme de la distribution d'origine tout en la recentrant, ce qui la rend adaptée à des variables continues dont les bornes réelles ne sont pas nécessairement connues à l'avance, ou qui peuvent contenir des valeurs extrêmes.

Normalisation Min-Max

La normalisation Min-Max ramène quant à elle chaque variable dans un intervalle fixe, généralement $[0, 1]$, selon la formule suivante :

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

où x_{min} et x_{max} sont respectivement les valeurs minimale et maximale observées pour la variable considérée. Cette technique est particulièrement adaptée lorsque les bornes réelles d'une variable sont connues et fixes, mais elle est plus sensible à la présence de valeurs extrêmes, qui peuvent écraser la répartition du reste des données dans l'intervalle.

Dans les deux cas, les modèles à base d'arbres (Arbre de Décision, Random Forest, XGBoost), qui raisonnent par seuils successifs plutôt que par distance ou combinaison linéaire, restent insensibles à cette mise à l'échelle.

3.3 Approche méthodologique et cartographie des modules

Les notions théoriques présentées dans la section précédente ne sont pas utilisées séparément : elles sont réparties dans trois modules distincts, chacun correspondant à une fonctionnalité du système. Le premier module estime la densité de tilapia à partir des caractéristiques du sol, le second détermine l'état actuel de la qualité de l'eau, et le troisième anticipe son évolution dans l'heure qui suit. Le tableau suivant présente, pour chaque module, l'objectif technique visé, le type de données utilisées et les algorithmes théoriques mobilisés parmi ceux vus précédemment

Module	Objectif technique	Type de données	Algorithmes mobilisés
Module 1 – Densité du tilapia via le sol	Régression : estimer une valeur continue de densité	Données tabulaires (paramètres du sol rizicole)	Régression Linéaire, SVR, Arbre de Décision, Random Forest, XGBoost – optimisés par GridSearch
Module 2 – Classification de l'état actuel de l'eau	Classification binaire : bonne ou mauvaise qualité	Données tabulaires (paramètres physico-chimiques de l'eau)	Régression Logistique, SVC, Arbre de Décision, Random Forest, XGBoost – optimisés par GridSearch
Module 3 – Anticipation de la qualité de l'eau à H+1	Prédiction temporelle : estimer l'état probable de l'eau une heure à l'avance	Séries temporelles (mesures successives de l'eau)	Décomposition STL combinée à un modèle LSTM

TABLE 8: Cartographie des trois modules du système

On remarque que les deux premiers modules reposent sur les mêmes familles d'algorithmes de machine learning, adaptées d'un côté à la régression et de l'autre à la classification, tandis que le troisième module suit une approche différente, combinant traitement du signal et deep learning, plus adaptée à des données séquentielles.

Le chapitre suivant présente la mise en œuvre pratique de ces trois modules, en détaillant la collecte, l'exploration et la préparation des données.

4 Méthodologie et préparation des données

4.1 Origine et collecte des données

Ce mémoire s'appuie sur deux jeux de données distincts, correspondant respectivement au module de prédiction de densité (Module 1) et aux modules de classification et de prédiction de la qualité de l'eau (Modules 2 et 3)

Données pour le Module 1 (densité de tilapia)

Les données utilisées pour l'estimation de la densité de tilapia à partir des caractéristiques du sol rizicole n'ont pas pu être collectées directement sur le terrain, faute d'accès à des parcelles instrumentées dans le cadre de ce mémoire. Un jeu de données synthétique a donc été généré pour ce module, à partir

de connaissances contextualisées sur les pratiques rizipiscicoles malagasy (types de sol rencontrés sur les Hautes-Terres, pratiques d'irrigation et de fertilisation locales). Cette approche, courante lorsqu'un accès direct aux données de terrain n'est pas possible, permet de disposer d'un jeu de données cohérent avec le contexte étudié pour développer et tester la démarche méthodologique. Ses limites - notamment l'absence de validation par des mesures réelles - sont discutées dans le chapitre de conclusion, et une piste d'amélioration du projet consistera à confronter ce modèle à des données de terrain réelles.

Données pour les Modules 2 et 3 (qualité de l'eau)

Les données utilisées pour la classification et la prédiction de la qualité de l'eau proviennent d'un jeu de données public, mis à disposition sur la plateforme Kaggle, rassemblant des mesures physico-chimiques d'eau destinées à l'élevage piscicole associées à une étiquette de qualité de l'eau. Le recours à un jeu de données public se justifie par la difficulté d'obtenir, dans le cadre d'un mémoire de Licence, des séries de mesures continues et fiables sur plusieurs mois directement depuis une parcelle rizipiscicole équipée de capteurs. Ce jeu de données présente néanmoins l'intérêt de couvrir les mêmes variables physico-chimiques que celles pertinentes pour le tilapia, ce qui permet de développer et valider la démarche de classification et de prédiction temporelle proposée dans ce mémoire.

4.2 Structure des datasets

Module 1 (densité de tilapia)

Ce dataset comprend 2000 observations, chacune correspondant à une parcelle rizipiscicole caractérisée par ses propriétés de sol, ses conditions d'irrigation et de fertilisation, ainsi que la densité de tilapia associée

Variable	Type	Description
Texture_sol	Catégorielle	Texture du sol (sableux, limoneux, argileux)
Couleur_sol	Catégorielle	Couleur du sol (indicateur de composition organique)
Type_irrigation	Catégorielle	Mode d'irrigation de la parcelle (irrigué en continu, pluvial)
Hauteur_Eau	Numérique (int)	Hauteur d'eau dans la parcelle (cm)
Niveau_Engrais	Catégorielle	Niveau de fertilisation appliqué
Temperature_Actuelle	Catégorielle	Catégorie de température ambiante
Densite_Tilapia_Are	Numérique (int)	Variable cible : densité de tilapia par are

TABLE 9: Structure du dataset – Module 1

Pour ce module, les variables `Texture_sol`, `Couleur_sol`, `Type_irrigation`, `Hauteur_Eau`, `Niveau_Engrais` et `Temperature_Actuelle` sont utilisées comme variables explicatives, tandis que `Densite_Tilapia_Are` constitue la variable cible à prédire.

Modules 2 et 3 (qualité de l'eau)

Ce dataset comprend environ 74 700 observations horodatées, correspondant à des relevés physico-chimiques successifs de l'eau, avec un pas de temps régulier de l'ordre de 20 minutes. Cette granularité temporelle fine en fait un jeu de données adapté aussi bien à la classification immédiate (Module 2) qu'à l'analyse temporelle et à la prédiction à court terme (Module 3)

TABLE 10: Structure du dataset – Modules 2 et 3

Variable	Type	Description
Date	Catégorielle (date)	Date de la mesure
Time	Catégorielle (heure)	Heure de la mesure
PH	Numérique (float)	pH de l'eau
TEMP	Numérique (float)	Température de l'eau
DO	Numérique (float)	Oxygène dissous
TURBIDITY	Numérique (float)	Turbidité de l'eau
tempC	Numérique (int)	Température ambiante (°C)
label	Catégorielle	Variable cible : qualité de l'eau (0 = mauvaise, 1 = bonne)

Pour le Module 2, les variables PH, TEMP, DO et TURBIDITY sont utilisées comme variables explicatives à un instant donné, avec label comme variable cible à prédire. Pour le Module 3, ces mêmes variables physico-chimiques sont réorganisées en séries temporelles grâce aux champs Date et Time, afin d'alimenter la décomposition STL puis le modèle LSTM chargé d'anticiper l'évolution de la qualité de l'eau à une heure.

4.3 Visualisation et analyse

Avant d'entraîner les modèles, une analyse exploratoire visuelle a été réalisée afin d'observer la distribution de la variable cible et son comportement en fonction des différentes caractéristiques.

Module 1 – Densité du tilapia

La Figure 2 présente la distribution de la variable cible Densite_Tilapia_Are.




FIGURE 2 – Distribution de la variable Densite_Tilapia_Are

Les figures suivantes présentent, sous forme de violin plots, la relation entre la densité de tilapia et chacune des variables du dataset.




FIGURE 3 – Densité de tilapia selon la hauteur d’eau




FIGURE 4 – Densité de tilapia selon la température actuelle

La Figure 3 montre une tendance croissante claire : la médiane de densité passe d’environ 17 tilapias/are pour une hauteur d’eau de 5-8 cm, à environ 27 pour 9-14 cm, puis à environ 32 pour 15-20 cm. Sur le plan pratique, cela confirme une réalité bien connue des rizipisciculteurs : une lame d’eau trop faible limite l’espace de vie et de nage des poissons et les expose davantage aux variations de température, tandis qu’une hauteur d’eau suffisante offre un habitat plus stable et plus propice à leur croissance.

La Figure 4 révèle quant à elle que la catégorie « chaud » est associée à la médiane de densité la plus élevée (environ 38), tandis que la catégorie « tres froid » présente la médiane la plus basse (environ 17) et la distribution la plus resserrée vers les faibles valeurs, confirmant la sensibilité du tilapia aux températures basses.




FIGURE 5 – Densité de tilapia selon le niveau d’engrais




FIGURE 6 – Densité de tilapia selon le type d’irrigation

La Figure 5 met en évidence une relation croissante entre le niveau de fertilisation et la densité de tilapia : la médiane passe d’environ 19 pour un niveau d’engrais nul, à environ 29 pour un niveau moyen, puis à environ 33 pour un niveau fort. cela s’explique par le fait que la fertilisation (notamment organique, comme le zezika traditionnellement utilisé à Madagascar) stimule le développement du plancton et des micro-organismes dont se nourrit le tilapia.

La Figure 6 montre par ailleurs que les parcelles en irrigation continue présentent une médiane de densité nettement plus élevée (environ 33) que les parcelles en irrigation pluviale (environ 22), suggérant qu’un apport d’eau régulier favorise la croissance du cheptel piscicole.




FIGURE 7 – Densité de tilapia selon la couleur du sol




FIGURE 8 – Densité de tilapia selon la texture du sol

La Figure 7 montre des médianes assez proches entre les couleurs de sol « Brun-Grisâtre » et « Orange/Rouge » (autour de 25-26), tandis que le sol « Noirâtre (Rich) » présente une médiane légèrement supérieure (environ 31), cohérente avec sa richesse organique généralement plus élevée.

Enfin, la Figure 8 révèle une tendance croissante selon la texture du sol : le sol sableux présente la médiane la plus basse (environ 20), le sol limoneux une médiane intermédiaire (environ 27), et le sol argileux la médiane la plus élevée (environ 34), ce dernier retenant probablement mieux l’eau et les nutriments nécessaires au développement du tilapia.

La Figure 9 présente la matrice de corrélation entre les variables explicatives encodées et la variable cible `Densite_Tilapia_Are`.




FIGURE 9 – Matrice de corrélation des variables du Module 1

On retrouve dans cette matrice les tendances déjà observées sur les violin plots précédents, désormais quantifiées. On remarque également que les variables explicatives sont globalement très peu corrélées

entre elles , ce qui est plutôt favorable pour les modèles de régression linéaire, en limitant les risques de multicollinéarité. Cela confirme aussi que chacune de ces six variables apporte une information relativement indépendante et complémentaire à la prédiction de la densité de tilapia, justifiant leur intégration conjointe dans les modèles du Module 1.

Modules 2 et 3 – Qualité de l’eau

Une analyse similaire a été menée sur le dataset de qualité de l’eau, en observant la distribution de chaque variable physico-chimique selon la classe de qualité (label = 0 pour mauvaise qualité, label = 1 pour bonne qualité), ainsi que l’équilibre général des classes.




FIGURE 10 – Distribution de la Turbidité selon la qualité de l’eau




FIGURE 11 – Distribution de la Température selon la qualité de l’eau

La Figure 10 montre une séparation assez nette entre les deux classes : les eaux de bonne qualité (label 1) se concentrent essentiellement entre 15 et 40 NTU, tandis que les eaux de mauvaise qualité (label 0) se répartissent surtout au-delà de 45 NTU, avec un pic marqué autour de 55-65. Concrètement, cela confirme qu’une eau trop trouble, chargée en particules en suspension, est un signal facilement identifiable de dégradation .

La Figure 11 révèle une séparation encore plus marquée : les eaux de bonne qualité se situent majoritairement entre 15°C et 35°C, tandis que les eaux de mauvaise qualité se concentrent au-delà de 37°C. Cela correspond à une réalité bien connue : l’eau perd sa capacité à retenir l’oxygène nécessaire à la respiration des poissons, ce qui la rend rapidement dangereuse.




FIGURE 12 – Distribution du pH selon la qualité de l'eau




FIGURE 13 – Distribution de l'Oxygène Dissous selon la qualité de l'eau

La Figure 12 montre que les eaux de bonne qualité se concentrent surtout entre 5 et 7,5, avec un pic net autour de 6, tandis que les eaux de mauvaise qualité se répartissent plus largement au-delà de 7,5 et se prolongent jusqu'à 9. Un pH trop élevé (une eau trop basique) peut dégrader la santé des poissons.

La Figure 13 montre que les oxygènes dissous dans les eaux de bonne qualité se concentrent principalement entre 4 et 10 mg/L, avec un pic vers 6-7, tandis que les eaux de mauvaise qualité se répartissent sur une plage plus large, avec une proportion notable de valeurs très faibles (proches de 0) et très élevées (au-delà de 20). Un manque d'oxygène dissous est l'une des causes les plus fréquentes et les plus rapides de mortalité massive des poissons, souvent la nuit ou par forte chaleur.

La Figure 14 présente la matrice de corrélation entre les différentes variables physico-chimiques et la variable cible.




FIGURE 14 – Matrice de corrélation entre les composants de l'eau

On observe que la variable TURBIDITY présente la corrélation la plus forte avec la qualité de l'eau (-0,48), ce qui confirme l'observation faite précédemment sur sa distribution : plus l'eau est trouble, plus elle a tendance à être classée en mauvaise qualité. La TEMP suit avec une corrélation de -0,35, cohérente

avec la sensibilité du tilapia aux eaux trop chaudes. Le PH présente quant à lui une corrélation positive de 0,25, indiquant qu'un pH plus élevé est associé plus souvent à une bonne qualité dans ce dataset, tandis que le DO (oxygène dissous) affiche une corrélation plus faible (-0,13), ce qui peut sembler surprenant compte tenu de son importance biologique connue pour la survie des poissons, mais qui s'explique par le fait que son influence n'est pas linéaire : c'est surtout un déficit sévère en oxygène qui devient critique, plutôt qu'une simple variation continue de sa valeur. Cela justifie qu'un modèle non linéaire (comme la Random Forest ou XGBoost) puisse mieux capter cette relation qu'un simple coefficient de corrélation. On note enfin que les variables explicatives sont globalement peu corrélées entre elles (par exemple 0,094 entre PH et DO), ce qui limite les risques de multicollinéarité pour les modèles de classification développés dans le Module 2.

La Figure 15 présente enfin la répartition globale des deux classes dans le dataset.




FIGURE 15 – Répartition des classes de qualité de l'eau

On observe un déséquilibre notable entre les deux classes : 54,746 observations sont étiquetées comme « bonne qualité » contre environ 20,012 comme « mauvaise qualité », soit une proportion d'environ 73 % / 27 %. Ce déséquilibre reflète une réalité plutôt rassurante sur le terrain : dans la majorité du temps, une parcelle correctement gérée conserve une eau de bonne qualité, les épisodes de dégradation restant l'exception plutôt que la norme. Cela confirme tout l'intérêt d'un système d'alerte : puisque les mauvais épisodes sont rares mais potentiellement lourds de conséquences (mortalité des poissons), il est essentiel de ne pas les manquer lorsqu'ils surviennent, ce qui devra être pris en compte dans le choix des métriques d'évaluation du modèle de classification (Module 2), afin de ne pas privilégier artificiellement la classe majoritaire au détriment de la détection des cas critiques.

4.4 Prétraitement des données

Avant l'entraînement des modèles, chaque dataset a fait l'objet d'étapes de nettoyage et de transformation spécifiques, adaptées à sa nature et à l'usage qui en est fait dans chacun des trois modules.

4.4.1 Module 1 – Densité du tilapia

Le dataset contient 75 doublons qui ont été supprimés. Contrairement à une variable catégorielle sans relation d'ordre, chacune des variables catégorielles explicatives de ce dataset possède en réalité une progression logique entre ses modalités : la température va du plus froid au plus chaud, le niveau d'engrais du plus faible au plus fort, la texture du sol du plus filtrant (sableux) au plus retenant (argileux), la couleur du sol du plus clair au plus foncé (indicateur croissant de richesse organique), et le type d'irrigation d'un apport ponctuel (pluvial) à un apport continu. Un encodage one-hot ferait perdre cette

information d'ordre, pourtant pertinente pour les modèles. Un encodage ordinal a donc été appliqué à la place, en associant à chaque modalité un entier croissant reflétant cette progression :

```
temperature_encoder = {
    "TresFroid":0,
    "Froid":1,
    "Humide":2,
    "Chaud":3,
    "TresChaud":4,
}
niveaux_engrais_encoder = {
    "Nul":0,
    "Moyen":1,
    "Fort":2
}
texture_sol_encoder = {
    "Sableux":0,
    "Limoneux":1,
    "Argileux":2,
}
couleur_sol_encoder = {
    "Orange_Rouge":1,
    "Brun_Grisatre":2,
    "Noir":3
}
type_irrigation_encoder = {
    "Pluvial":0,
    "Continu":1
}
```

Cet encodage permet aux modèles, notamment ceux sensibles à la structure des variables comme la Régression Linéaire ou le SVR, d'exploiter directement la relation d'ordre entre les modalités, plutôt que de les traiter comme des catégories indépendantes sans lien entre elles.

Mise à l'échelle

Conformément à la méthode de standardisation présentée en 3.2.4, les variables explicatives encodées du Module 1 (température, niveau d'engrais, texture et couleur du sol, type d'irrigation, hauteur d'eau) sont standardisées, afin de les ramener sur une échelle comparable avant l'entraînement des modèles sensibles à l'amplitude des variables, tels que la Régression Linéaire et le SVR.

4.4.2 Module 2 – Classification de l'état actuel de l'eau

Le dataset brut contenait 51 valeurs manquantes réparties sur ses 74 758 observations, soit une proportion négligeable (moins de 0,01 % des cellules). Ces lignes incomplètes ont été supprimées plutôt qu'imputées, cette faible proportion ne justifiant pas de complexifier le traitement par une méthode d'imputation. Aucun doublon n'a par ailleurs été détecté. La variable cible `label` étant déjà représentée sous forme binaire (0/1), aucun encodage supplémentaire n'est nécessaire pour celle-ci.

4.4.3 Module 3 – Anticipation de la qualité de l'eau à H+1

Le dataset brut, échantillonné toutes les 20 minutes, a été rééchantillonné à un pas de temps horaire, plus adapté à l'horizon de prédiction visé d'une heure, ce qui a réduit le dataset à 24 920 lignes, sans aucune valeur manquante après ce rééchantillonnage. Ce nouveau pas de temps régulier est indispensable pour appliquer la décomposition STL, qui nécessite une série temporelle à fréquence constante.

Une fois ce rééchantillonnage effectué, chaque variable physico-chimique est décomposée selon la méthode STL présentée en 3.2.2, en trois composantes : la tendance T_t , la saisonnalité S_t et le résidu R_t . Ces trois composantes ne sont cependant pas traitées de la même façon dans la suite du pipeline.

La composante de tendance T_t , qui capture l'évolution de fond de la série, est celle qui alimente directement le modèle LSTM chargé de la prédiction à l'horizon d'une heure. La composante saisonnière S_t , quant à elle, correspond à un motif cyclique récurrent : plutôt que d'être réinjectée dans le modèle, elle est stockée séparément dans une base de données, et pourra être rajoutée à la prédiction de tendance issue du LSTM pour reconstituer une estimation complète de la valeur future.

Le résidu R_t , en revanche, est omis du pipeline de prédiction. Ce choix se justifie par le fait que la somme de la tendance et de la saisonnalité représente déjà environ 90 % de la variance de la série originale, le résidu ne représentant donc qu'une faible part de l'information totale, correspondant essentiellement à du bruit de mesure difficilement prévisible par nature. Intégrer ce résidu dans le modèle LSTM risquerait ainsi d'introduire davantage de bruit dans l'apprentissage sans réel gain de performance, alors que son omission permet de simplifier le signal appris par le modèle et de concentrer sa capacité de prédiction sur les composantes réellement structurantes de la série.

Feature Engineering

Pour entraîner le modèle LSTM sur la composante de tendance T_t , celle-ci est restructurée selon une approche de fenêtre glissante : les trois derniers pas de temps de tendance (T_{t-3} , T_{t-2} , T_{t-1}) constituent les variables d'entrée (lags), tandis que la valeur de tendance à l'instant présent (T_t) constitue la variable cible à prédire. Cette formulation permet au modèle d'apprendre la relation entre l'évolution récente de la tendance et sa valeur suivante, ce qui correspond à l'usage classique des réseaux LSTM pour la prédiction de séries temporelles à un pas.

4.4.4 Mise à l'échelle

Les variables physico-chimiques des Modules 2 et 3 (PH, TEMP, DO, TURBIDITY) possèdent des bornes physiques connues et fixes, propres à leur nature de mesure de capteur (par exemple un pH compris entre 0 et 14). Conformément à la méthode présentée en 3.2.4, une normalisation Min-Max (MinMaxScaler) est donc appliquée à ces variables, afin de les ramener dans un intervalle commun [0, 1] avant l'entraînement des modèles sensibles à l'échelle des données (Régression Logistique, SVC pour le Module 2), ainsi qu'avant leur intégration dans le réseau LSTM du Module 3, pour lequel une mise à l'échelle homogène des entrées facilite et stabilise l'apprentissage.

4.5 Stratégie d'évaluation et découpage des données

Une fois les données prétraitées, une stratégie d'évaluation adaptée à la nature de chaque tâche (régression, classification, prédiction temporelle) est nécessaire afin de mesurer honnêtement la capacité des modèles à généraliser, et de choisir des métriques pertinentes au regard des enjeux propres à chaque module.

4.5.1 Module 1 – Densité du tilapia

Découpage des données

Le dataset est séparé en un ensemble d'entraînement et un ensemble de test selon une proportion de 80 %/20 %. Le découpage est réalisé de façon aléatoire, la variable cible étant continue et ne présentant pas de déséquilibre de classes à préserver. L'ensemble de test n'intervient à aucun moment dans la phase d'entraînement ou d'optimisation des hyperparamètres, afin de fournir une estimation non biaisée de la performance finale des modèles.

Validation croisée et métriques

Sur l'ensemble d'entraînement, une validation croisée à 3 folds est utilisée conjointement au GridSearch (voir 3.2.3) pour sélectionner les meilleurs hyperparamètres de chaque modèle. La performance finale de chaque modèle est ensuite mesurée sur l'ensemble de test à l'aide de quatre métriques adaptées à un problème de régression :

- la RMSE (Root Mean Squared Error), qui pénalise davantage les erreurs importantes et s'exprime dans la même unité que la variable cible ;
- la MAE (Mean Absolute Error), plus simple à interpréter, qui donne l'écart moyen absolu entre la densité prédite et la densité réelle ;
- la MAPE (Mean Absolute Percentage Error), qui exprime cette erreur moyenne en pourcentage de la valeur réelle, facilitant l'interprétation relative de l'erreur indépendamment de l'échelle de la densité ;
- le R^2 (coefficient de détermination), qui indique la proportion de la variance de la densité de tilapia expliquée par le modèle.

Ces quatre métriques sont calculées pour chacun des cinq modèles présentés en 3.2.1 (Régression Linéaire, SVM, Arbre de Décision, Random Forest, XGBoost), afin de les comparer sur une base commune.

4.5.2 Module 2 – Classification de l'état actuel de l'eau

Découpage des données

Comme pour le Module 1, le dataset est séparé en un ensemble d'entraînement et un ensemble de test selon une proportion de 80 %/20 %. Cependant, le déséquilibre des classes observé en 4.3 (environ 73 % de bonne qualité contre 27 % de mauvaise qualité) impose un découpage stratifié, qui conserve cette même proportion dans les deux sous-ensembles, évitant qu'un des deux ne se retrouve avec une répartition de classes trop différente de l'originale.

Validation croisée et métriques

La validation croisée utilisée pour le GridSearch est également stratifiée, pour la même raison. Concernant l'évaluation finale, l'accuracy seule ne suffit pas à juger correctement un modèle sur un dataset déséquilibré : un modèle qui prédirait systématiquement « bonne qualité » obtiendrait déjà une accuracy proche de 73 % sans avoir rien appris d'utile. Quatre métriques sont donc utilisées conjointement :

- l'Accuracy, qui donne la proportion globale de prédictions correctes, mais qui doit être interprétée avec prudence compte tenu du déséquilibre des classes ;
- la Precision, qui mesure, parmi les observations prédites comme « mauvaise qualité », la proportion réellement mauvaise ;
- le Recall (rappel), qui mesure, parmi les observations réellement de « mauvaise qualité », la proportion correctement détectée par le modèle - la métrique la plus critique ici, puisqu'un cas de mauvaise qualité non détecté (faux négatif) expose directement les poissons à un risque, alors qu'une fausse alerte (faux positif) n'a qu'un coût opérationnel limité ;

- le F1-score, qui combine Precision et Recall en une seule valeur, utile pour comparer les modèles entre eux de façon synthétique.

4.5.3 Module 3 – Anticipation de la qualité de l’eau à H+1

Découpage des données

Contrairement aux deux modules précédents, le découpage entraînement/test ne peut pas être aléatoire pour une série temporelle : il doit respecter l’ordre chronologique des observations, afin d’éviter que le modèle n’apprenne à partir d’informations futures qu’il ne posséderait pas en conditions réelles d’utilisation. L’ensemble d’entraînement correspond ainsi à la première partie chronologique de la composante de tendance T_t restructurée en fenêtres glissantes, et l’ensemble de test à la période la plus récente.

Validation et métriques

La performance du modèle LSTM est évaluée sur sa capacité à prédire T_t à partir de T_{t-3} , T_{t-2} et T_{t-1} , à l’aide des quatre mêmes métriques que pour le Module 1 : la RMSE, la MAE, la MAPE et le R^2 , ce qui permet d’apprécier à la fois l’ampleur absolue et relative de l’erreur de prédiction sur la tendance.

5 Mise en œuvre et évaluation des modules

Ce chapitre constitue le cœur empirique de ce mémoire. Là où le Chapitre 3 a posé les fondements théoriques des modèles mobilisés et où le Chapitre 4 a préparé et structuré les données nécessaires, ce chapitre concrétise cette approche en mettant réellement en œuvre les trois modules du système rizipiscicole, puis en évaluant leurs performances respectives.

5.1 Environnement de développement et outils

5.1.1 Matériel et écosystème logiciel

L’ensemble du projet est développé en Python (version 3), devenu depuis plusieurs années le langage de référence de l’industrie pour les projets d’intelligence artificielle et de science des données, grâce à la richesse de son écosystème de bibliothèques dédiées et à la simplicité de sa syntaxe. Le développement est réalisé au sein d’un environnement de développement interactif de type Jupyter Notebook et Google Colab.

5.1.2 Bibliothèques de manipulation et de visualisation de données

La manipulation des données repose principalement sur Pandas, qui structure les données sous forme de DataFrames et facilite leur nettoyage, leur filtrage et leur transformation, ainsi que sur NumPy, qui fournit les structures de tableaux et les opérations matricielles et vectorielles nécessaires aux calculs numériques sous-jacents à la plupart des algorithmes de machine learning.

Pour la visualisation, Matplotlib et Seaborn sont utilisés conjointement : Matplotlib pour la génération de graphiques de base, et Seaborn, construit au-dessus de Matplotlib, pour des visualisations statistiques plus élaborées (distributions, violin plots, heatmaps de corrélation), ainsi que pour la représentation des courbes d’apprentissage et des matrices de confusion utilisées dans l’évaluation des modèles.

5.1.3 Écosystème de Machine Learning et optimisation

La bibliothèque Scikit-Learn constitue le socle du projet pour les modèles de machine learning classiques présentés en 1.2.1 : elle fournit une implémentation standardisée et éprouvée de la Régression Li-

néaire, de la Régression Logistique, des SVM (SVC/SVR), des Arbres de Décision et des Random Forest, avec une interface commune facilitant leur comparaison. Elle fournit également la classe `GridSearchCV`, qui automatise la recherche par grille combinée à la validation croisée présentée en 3.2.3, permettant d'optimiser systématiquement les hyperparamètres de chacun de ces modèles. Pour l'algorithme XGBoost, la bibliothèque officielle du même nom est utilisée, celle-ci étant spécifiquement optimisée pour l'implémentation du Boosting de gradient extrême, aussi bien pour sa variante de régression (XGBRegressor) que de classification (XGBClassifier).

5.1.4 Outils d'analyse temporelle et de Deep Learning

Pour la composante temporelle du Module 3, la bibliothèque Statsmodels est utilisée afin d'extraire les composantes de tendance, de saisonnalité et de résidu de chaque variable physico-chimique de l'eau, via son implémentation de la décomposition STL présentée en 3.2.2. Enfin, le framework TensorFlow, à travers son interface Keras, est utilisé pour concevoir, compiler et entraîner l'architecture du réseau de neurones récurrent LSTM dédié à la prédiction de la qualité de l'eau à l'horizon d'une heure, ce framework étant aujourd'hui l'un des standards de l'industrie pour le développement de modèles de deep learning.