



INSI

INSTITUT NATIONAL SUPERIEUR D'INFORMATIQUE

Mémoire de projet en vue de la validation de la Licence 2

Domaine : Sciences et Technologie

Mention : Informatique

Parcours : Intelligence Artificielle et Data

Par : - RAMAHANDRIMALALA Lova Andriamirahasina

- ANDRIANJAKA Idris Tovonirina

Prévision du risque de non-remboursement de prêts dans les banques ou IMFs

Date du début et fin du projet :

12 Juin 2025 - 31 Août 2025

Soutenu le 05 Août 2025, devant la commission d'examen composée de :

Président du Jury :

Dr RAJAOSOLOMANANTENA Haingonirina Ignace

Examineur :

Mr RASOLOFOMANANA Tolotra Iarivony Nirina

Encadreur :

Dr RAMASONDRANO Andriamanjaka

RESUME

Ce mémoire porte sur la prévision du risque de non-remboursement de prêts dans les banques et les institutions de microfinance (IMFs). L'objectif principal est d'identifier et d'analyser les facteurs qui influencent le comportement des emprunteurs afin de minimiser le risque financier.

Nous avons d'abord effectué une revue de la littérature sur les méthodes traditionnelles et modernes d'évaluation du risque de crédit. Les approches statistiques, y compris la régression logistique et les arbres de décision, sont examinées, ainsi que les techniques d'apprentissage automatique qui gagnent en popularité dans le domaine.

Pour notre étude, nous avons utilisé un ensemble de données comprenant des informations socio-économiques des emprunteurs, des caractéristiques des prêts et des historiques de remboursement. À l'aide d'analyses descriptives et de modèles prédictifs, nous avons identifié plusieurs variables clés, telles que le taux d'endettement, le niveau de revenu et la stabilité professionnelle, qui influencent significativement le risque de non-remboursement.

Les résultats montrent que l'application de modèles avancés permet d'améliorer la précision des prévisions et de mieux cibler les stratégies de gestion du risque. Enfin, des recommandations pratiques sont proposées pour les banques et IMFs, afin d'optimiser leurs processus de prêt et de renforcer leur résilience face aux défauts de paiement.

Mots-clés : risque de non-remboursement, prêts, banques, institutions de microfinance, modèles prédictifs, apprentissage automatique, régression logistique, RandomForest, XGboost, SVM, KNN, Naives Bayes, SHAP.

ABSTRACT

This thesis focuses on the prediction of loan default risk in banks and microfinance institutions (MFIs). The primary objective is to identify and analyze the factors influencing borrower behavior to minimize financial risk.

We first conducted a literature review on traditional and modern methods for assessing credit risk. Statistical approaches, including logistic regression and decision trees, are examined, along with machine learning techniques that are gaining popularity in the field.

For our study, we utilized a dataset comprising socio-economic information of borrowers, loan characteristics, and repayment histories. Through descriptive analyses and predictive modeling, we identified several key variables, such as debt-to-income ratio, income level, and job stability, which significantly influence the risk of default.

The results indicate that the application of advanced models enhances prediction accuracy and better targets risk management strategies. Finally, practical recommendations are proposed for banks and MFIs to optimize their lending processes and strengthen their resilience against payment defaults.

Keywords : default risk, loans, banks, microfinance institutions, predictive models, machine learning, logistic regression, RandomForest, XGboost, SVM, KNN, Naives Bayes, SHAP .

Table des matières

1	Introduction Générale	1
2	Présentation de l'INSI	2
2.1	Information d'ordre général	2
2.2	Missions et historiques	2
2.3	Organigramme de l'INSI	3
2.4	Domaine de spécialisation	5
2.4.1	Licences professionnelles	5
2.4.2	Masters professionnels	5
2.4.3	Formations professionnelles	5
2.4.4	Mobilité internationale & double diplôme	6
2.5	Architectures des formations pédagogiques	6
2.6	Relations de l'INSI avec les entreprises et les organismes	7
2.7	Partenariat au niveau international	8
2.8	Parcours professionnels des diplômés	8
2.9	Ressources humaines	10
3	Cadrage	11
3.1	Importance des solutions apportées	12
3.1.1	Amélioration des modèles de risque de crédit	12
3.1.2	Objectifs et impacts attendus	12
4	État de l'Art	13
4.1	Concepts clés utilisés dans le projet	13
4.2	Solutions existantes et comparaison	13
4.3	Justification du choix de la solution	14
5	Origine et construction des données	15
5.1	Définition et justification des variables	15
5.2	Les variables de nos données	16
5.3	Les 15 variables sélectionnées et importantes	17
5.4	Perspectives d'utilisation	18
6	Modèles	19

6.1	Analyse des Variables	19
6.2	Analyse des Distributions	21
6.3	Régression Logistique	27
6.3.1	Principe	27
6.3.2	Points clés :	28
6.3.3	Résultats et interprétation	28
6.4	Random Forest	29
6.4.1	Principe	29
6.4.2	Résultats et interprétation	29
6.5	XGBoost	29
6.5.1	Principe	29
6.5.2	Résultats et interprétation	30
6.6	K-Nearest Neighbors (KNN)	31
6.6.1	Principe	31
6.6.2	Résultats et interprétation	31
6.7	Naive Bayes	31
6.7.1	Principe	31
6.7.2	Résultats et interprétation	32
6.8	SHAP	32
6.8.1	Principe	33
6.8.2	Utilisation avec les modèles	33
6.8.3	Forces et limites	33
6.9	LIME (Local Interpretable Model-agnostic Explanations)	34
6.9.1	Principe	34
6.9.2	Résultats et interprétation	35
6.10	Support Vector Machine (SVM)	35
6.10.1	Principe	35
6.10.2	Points clés :	35
6.10.3	Résultats et interprétation	35
6.11	Justification du choix du SVM	36
6.12	Synthèse comparative des modèles	37
6.12.1	Commentaires globaux	37

7 Déploiement 38

8	Conclusion Générale	40
9	ANNEXES	II

Listes des Figures

1	Organigramme de l'INSI	3
2	Boxplot Credit Score	19
3	Boxplot dtr1	19
4	Boxplot de Income	20
5	Boxplot de Interest Rate Spread	20
6	Boxplot de Loan Amount	20
7	Boxplot de LTV	20
8	Boxplot de Property Value	21
9	Boxplot de Rate of Interest	21
10	Boxplot de Term	21
11	Boxplot de Upfront Charges	21
12	Distribution de l'âge	22
13	Distribution de approv_in_adv	22
14	Distribution de co-applicant credittype	22
15	Distribution de construction type	22
16	Distribution de credit type	23
17	Distribution de Credit Worthiness	23
18	Distribution de Income	23
19	Distribution de Interest Rate Spread	23
20	Distribution de Credit Score	24
21	Distribution de DTIR1	24
22	Distribution de Loan Amount	24
23	Distribution de LTV	24
24	Distribution de Property Value	24
25	Distribution de Rate of Interest	24
26	Distribution de Term	25
27	Distribution de Upfront Charges	25
28	Distribution de Gender	25
29	Distribution de Interest Only	25
30	Distribution de Loan Limit	25
31	Distribution de Loan Purpose	25
32	Distribution de Loan Type	26

33	Distribution de Lump Sum Payment	26
34	Distribution de Neg Amortization	26
35	Distribution de Occupancy Type	26
36	Distribution de Open Credit	26
37	Distribution de Region	26
38	Distribution de Secured By	27
39	Distribution de Security Type	27
40	Distribution de Submission of Application	27
41	Distribution de Total Units	27
42	Courbe ROC - Régression Logistique	28
43	Importance des variables - Random Forest	30
44	Courbe ROC - XGBoost	31
45	KNN	32
46	Naives Bayes	33
47	SHAP	34
48	Matrice de confusion - SVM	36
49	Ouverture de la page web	38
50	Entrée du nom d'utilisateur ou connexion via Google	38
51	Créer un compte	38
52	Se connecter via Google	38
53	Page d'accueil après connexion	39
54	PDF contenant les informations du client	39
55	Activation de n8n	39
56	Analyse du PDF	39
57	Dossier accepté	39
58	n8n exécuté	39
59	Boxplot de ID	II
60	Boxplot de Status	II
61	Boxplot de Year	II
62	Distribution de ID	II
63	Distribution de Status	II
64	Distribution de Year	II

Liste des tableaux

1	Les parcours en Licence et Master	6
2	Comparaison des performances et caractéristiques des modèles	37

1 Introduction Générale

La prévision du risque de non-remboursement de prêts est un enjeu crucial pour les banques et les institutions de microfinance (IMFs), car l'augmentation des défauts de paiement peut entraîner des conséquences graves sur la stabilité financière et la confiance des investisseurs. Dans ce contexte, notre projet vise à développer des outils et des méthodes permettant d'évaluer plus précisément ce risque. Pour atteindre cet objectif, plusieurs actions ont été menées : une analyse de la littérature existante a permis d'identifier les approches les plus efficaces pour évaluer le risque de crédit ; les données nécessaires ont été collectées et traitées, en intégrant des facteurs socio-économiques ainsi que des caractéristiques des prêts afin de constituer un ensemble de données robuste ; différents modèles prédictifs ont été développés à l'aide de techniques statistiques et d'algorithmes d'apprentissage automatique tels que la régression logistique, RandomForest, XGBoost, SVM, KNN, Naïves Bayes, SHAP ; la performance de ces modèles a ensuite été évaluée en comparant leur précision et leur capacité à prédire le risque de non-remboursement ; enfin, des recommandations pratiques ont été formulées à destination des banques et des IMFs pour améliorer leurs processus de décision et de gestion du risque. Le présent mémoire est structuré en plusieurs parties : une introduction générale du projet ; un cadrage qui présente le cadre théorique et les enjeux liés à la problématique ; une section dédiée aux données utilisées, à leur source et à leur traitement ; une partie consacrée aux modèles développés et à leur évaluation ; une analyse des résultats et leur validation ; et une conclusion générale qui propose une synthèse des travaux ainsi que des recommandations concrètes pour les acteurs concernés. Cette organisation vise à offrir une approche cohérente et complète de la problématique, en alliant des analyses théoriques et des expérimentations pratiques.

2 Présentation de l'INSI

2.1 Information d'ordre général

INSI (Institut National Supérieur d'Informatique) est un institut universitaire situé à Antananarivo, spécialisé dans le domaine de l'informatique. Il accueille principalement des bacheliers ayant choisi cette filière, mais reste également ouvert à toute personne manifestant un intérêt particulier pour les métiers du numérique, à travers son centre de formation professionnelle. L'établissement a été fondé le 17 août 2021 et son siège se trouve à Ankazotokana Ambanidia, Lot VF 32 Ter. Pour tout renseignement, vous pouvez nous contacter par email à contact@insi.mg ou visiter notre site web : www.insi.mg INSI University bénéficie du soutien d'entreprises partenaires, dont Ilo Madagascar SARLU et Data Pulse Center, qui sont également à l'origine de sa création.

2.2 Missions et historiques

INSI University a été fondée le 17 août 2021 à Antananarivo, dans un contexte marqué par une forte demande de compétences dans le domaine de l'informatique et des technologies numériques, Créé à l'initiative de Ilo Madagascar SARLU et Data Pulse Center, l'Institut a vu le jour avec pour ambition de former une nouvelle génération de professionnels qualifiés, capables de répondre aux besoins du marché local et international. Depuis sa création, INSI ne cesse d'évoluer en adaptant ses formations aux enjeux technologiques actuels, tout en favorisant un apprentissage pratique, orienté vers les réalités du monde professionnel. La mission principale de l'INSI est de former des experts compétents, éthiques et innovants dans le domaine de l'informatique, capables de contribuer activement au développement économique et numérique de Madagascar.

L'Institut s'engage à :

- Offrir des formations de qualité, à jour des évolutions technologiques,
- Favoriser l'insertion professionnelle de ses apprenants,
- Créer un lien fort entre la formation académique et les besoins réels des entreprises,
- Encourager l'entrepreneuriat et l'innovation technologique,
- Contribuer à la démocratisation de l'accès au savoir numérique.

2.3 Organigramme de l'INSI

L'organigramme ci-dessous présente la structure organisationnelle de l'INSI, mettant en évidence les différentes fonctions et responsabilités au sein de l'institut, ainsi que les liens hiérarchiques entre les divers services.




FIGURE 1 – Organigramme de l'INSI
Source : INSI, 2025

L'organigramme de l'INSI, en partenariat avec le Collège de Paris, est structuré autour d'une direction générale incarnée par le Président Directeur Général. Ce dernier assure la coordination de trois pôles principaux : la Direction Administrative et Financière, la Direction des Études, et le service des Relations Internationales et Mobilités.

Le Président Directeur Général assure la direction stratégique de l'institut. Il supervise l'ensemble des activités pédagogiques, administratives et de développement.

Il veille à la qualité de l'enseignement, à la bonne gestion des ressources humaines et matérielles, et représente l'établissement auprès des partenaires et autorités.

La Direction Administrative et Financière est chargée de la gestion des affaires internes, notamment à travers deux services essentiels : le service des scolarités, qui s'occupe des dossiers étudiants, inscriptions et suivi académique, et les services supports et stratégiques, qui assurent un appui logistique, administratif et technologique à l'ensemble de l'institut.

Le pôle des Relations Internationales et Mobilités gère les échanges académiques avec l'étranger ainsi que les projets de mobilité étudiante ou enseignante.

La Direction des Études supervise quant à elle l'ensemble des programmes pédagogiques et le corps enseignant. Elle travaille en étroite collaboration avec un Responsable Parcours, qui coordonne les différentes spécialisations proposées. Cette direction intègre également une cellule dédiée à la formation professionnelle et à la certification, en charge des dispositifs de validation des compétences, des certifications professionnelles et des parcours de formation continue. Il comprend également le Département alternance et emplois, responsable du suivi des étudiants en contrat d'alternance, des stages professionnels, et de l'insertion professionnelle.

Sous la partie Responsable Parcours, plusieurs responsables pédagogiques gèrent les différentes filières de formation : le parcours tronc commun, qui regroupe les matières fondamentales partagées par tous les étudiants en début de cycle ; le parcours ARSB & IC ; le parcours GL & MSI ; et enfin le parcours IAD & I2AD.

D'autres structures, bien que non représentés sur cet organigramme, contribuent également de manière significative à la mission de l'INSI. Le Conseil de l'École, Il regroupe des membres de l'équipe pédagogique et administrative. Il joue un rôle consultatif ou décisionnel sur les questions académiques : validation des programmes, suivi des résultats, discipline, méthodologie, etc.

Le responsable de la formation en ligne, Il conçoit et supervise les dispositifs d'apprentissage à distance. Il s'assure que les contenus en ligne sont accessibles, interactifs et conformes aux standards pédagogiques, tout en accompagnant enseignants et étudiants dans leur utilisation.

L'Association et Clubs étudiants, encadre et soutient les initiatives étudiantes, les clubs thématiques (informatique, innovation, sport, culture, etc.), et les événements organisés dans le cadre de la vie étudiante. Cela favorise l'engagement, le développement personnel et les compétences transversales des étudiants.

Cette structure témoigne d’une organisation à la fois pédagogique, administrative et tournée vers l’international et l’employabilité, assurant une formation complète et professionnalisante aux étudiants.

2.4 Domaine de spécialisation

INSI University propose des parcours académiques professionnalisants dans le domaine de l’informatique et des technologies numériques, articulés autour de licences professionnelles, de masters spécialisés, formations professionnelles continues et d’opportunités de mobilité internationale.

2.4.1 Licences professionnelles

Les programmes de licence offrent une formation de base solide, axée sur la pratique, et préparant à une insertion rapide dans le monde professionnel :

- GL (Génie Logiciel) : Conception, développement et maintenance d’applications logicielles.
- ARSB (Administration Réseaux et Systèmes et Base de données) : Gestion d’infrastructures informatiques, réseaux, serveurs et systèmes.
- IAD (Intelligence Artificielle et Data Science) : Introduction aux algorithmes d’IA, au traitement de données et à l’apprentissage automatique.

2.4.2 Masters professionnels

Les masters permettent d’approfondir les compétences techniques et managériales, en lien étroit avec les évolutions du secteur :

- MSI (Management des Systèmes d’Information) : Pilotage de projets numériques, gouvernance des SI.
- IC (Infrastructures et Cybersécurité) : Sécurisation des systèmes, audit, réseaux avancés.
- I2AD (Intelligence Artificielle, Analyse de Données et Automatisation) : Applications avancées de l’IA, automatisation des processus et science des données.

2.4.3 Formations professionnelles

INSI University propose également des formations professionnelles continues, spécifiquement conçues pour les professionnels déjà en poste souhaitant approfondir leurs compétences ou se spécialiser dans l’un des domaines proposés.

Ces formations sont adaptées aux contraintes des professionnels (horaires flexibles, modules pratiques) et visent à renforcer leur employabilité ou à accompagner leur évolution de carrière.

2.4.4 Mobilité internationale & double diplôme

Dans une optique d'ouverture et de reconnaissance internationale, INSI propose à ses étudiants des opportunités de mobilité académique et de double diplôme, à partir de la deuxième année (L2).

- Format hybride : 6 mois de formation à Madagascar + 6 mois à l'étranger selon le parcours choisi.
- Double diplôme en L3 ou M2 : En partenariat avec des institutions internationales telles que :
 - Collège de Paris (France)
 - Keyce Informatique (France)
 - Eskills (Québec, Canada)

Conditions d'éligibilité

- Niveau DALF C1 en français pour la mobilité vers des pays francophones.
- Niveau B2 ou C1 en anglais pour les destinations anglophones.

2.5 Architectures des formations pédagogiques

Le recrutement des étudiants à l'INSI s'effectue exclusivement par sélection de dossiers pour l'entrée en première année de Licence (L1), et par voie de concours pour l'admission en Master 1. Au sein de l'INSI, une seule mention est proposée : Informatique, déclinée en trois parcours distincts aux niveaux Licence et Master :

Licence	Master
Génie Logiciel (GL)	Management des Systèmes d'Information (MSI)
Administration Réseaux, Systèmes et Bases de données (ARSB)	Infrastructures et Cybersécurités (IC)
Intelligence Artificielle et Data Science (IAD)	Intelligence Artificielle, Analyse de Données et Automatisation (I2AD)

TABLE 1 – Les parcours en Licence et Master
Source : INSI, 2025

L'architecture des études à trois niveaux conformément au système LMD (Licence Master et Doctorat) permet les comparaisons et les équivalences académiques des diplômes au niveau international.

L = Licence (Bac + 3) = L1, L2, L3 = 6 semestres S1 à S6

M = Master (Bac + 5) = M1, M2 = 4 semestres S7 à S10

Le diplôme de licence est obtenu en 3 années des études après Baccalauréat. Et le diplôme de Master est obtenu en 2 ans après obtenu du diplôme de LICENCE. Le MASTER PROFESSIONNEL est un diplôme destiné à la recherche emploi au terme des études.

Spécificités pédagogiques

- École d’alternance dès la L2 S4 Alternance cours/entreprise pour une meilleure insertion
- Écoles connectées & e-learning Plateforme numérique de formation, cloud intégré, Google Workspace Cours accessibles en ligne selon les parcours
- Pédagogie active & par projets Hackathons, soutenances exposées, projets réels en entreprise

2.6 Relations de l’INSI avec les entreprises et les organismes

L’Institut National Supérieur en Informatique (INSI) entretient des liens étroits avec le monde professionnel. L’INSI collabore activement avec de nombreux organismes publics, semi-publics et privés, tant au niveau national qu’international. Cette collaboration se traduit concrètement par l’organisation régulière de stages obligatoires pour les étudiants, favorisant leur immersion professionnelle et leur employabilité.

Parmi les entreprises et institutions partenaires accueillant nos étudiants en stage chaque année, on peut citer : Data Pulse Center, RELIA Consulting, Code Talent, Bocasay, Minimad, Smartone AI, NOVITY, Eclasia Madagascar, VISEO Groupe, Océane Trade, ACCES Banque, ...

En plus des stages, l’INSI organise régulièrement des visites pédagogiques, des rencontres métiers et des projets collaboratifs avec plusieurs entreprises du secteur technologique et numérique. Ces activités permettent aux étudiants de mieux comprendre les réalités du terrain, d’échanger avec des professionnels et de s’ouvrir à l’environnement entrepreneurial.

Parmi les entreprises ayant accueilli ces initiatives : NOVITY, YAS Madagascar, Smartone AI, Eclasia Madagascar, et d’autres acteurs majeurs du numérique à Madagascar. Cette dynamique de partenariat permanent constitue un pilier de la pédagogie à l’INSI, en lien avec son objectif de former des professionnels compétents, opérationnels et ancrés dans les besoins du marché.

2.7 Partenariat au niveau international

L'INSI s'est inscrit dans une dynamique d'ouverture à l'international grâce à son partenaire fondateur, ILO Madagascar, représentant de l'Organisation Internationale du Travail. Cette orientation se renforce aujourd'hui à travers des partenariats stratégiques avec des institutions académiques et des entreprises internationales, permettant à l'Institut de proposer une formation alignée sur les standards mondiaux.

L'INSI bénéficie actuellement de programmes de co-diplomation et de double diplôme en collaboration avec plusieurs établissements internationaux de renom, tels que :

- Collège de Paris International
- Keyce Informatique (France)
- Eskills Academy (Québec, Canada)
- École Supérieure Polytechnique d'Antsiranana (ESPA) – pour une synergie régionale renforcée.

Ces partenariats permettent non seulement d'enrichir l'offre pédagogique, mais aussi d'ouvrir des perspectives de mobilité académique et professionnelle aux étudiants, en leur offrant une reconnaissance de leurs compétences à l'échelle internationale.

Par ailleurs, à travers les stages annuels et projets pédagogiques, l'INSI collabore également avec des entreprises à dimension régionale ou mondiale, telles que :

- VISEO Group
- Eclosia Madagascar (Groupe mauricien)
- Smartone AI
- NOVITY, entre autres.

Ces relations actives témoignent de l'ancrage de l'INSI dans un écosystème global, plaçant l'Institut comme un acteur majeur de la formation en informatique à Madagascar, tourné vers l'innovation et les exigences du marché international.

2.8 Parcours professionnels des diplômés

Les diplômés de la Licence en Informatique de l'INSI disposent d'un socle solide de compétences en programmation, systèmes, réseaux, bases de données et développement logiciel. Cette polyvalence

leur permet d'intégrer directement le marché du travail ou de poursuivre en Master. À ce niveau, ils peuvent exercer en tant que :

- Technicien système et réseau
- Développeur web / mobile (front-end ou back-end)
- Administrateur systèmes junior
- Technicien support IT
- Intégrateur / testeur logiciel
- Assistant en sécurité informatique
- Assistant en projets d'IA ou de data (selon profil)

Les stages annuels en entreprise leur offrent une première expérience professionnelle valorisante dans des structures variées : entreprises technologiques, banques, administrations, startups, ONG, etc. La formation de Master proposée à l'INSI, grâce à ses parcours spécialisés, forme des professionnels capables d'intervenir sur des projets complexes, innovants et à dimension stratégique. Les débouchés varient selon la spécialisation choisie :

Parcours Ingénierie logicielle, réseaux et systèmes :

- Ingénieur en développement logiciel / full-stack
- Architecte logiciel
- Ingénieur systèmes et réseaux
- Administrateur cloud / DevOps
- Chef de projet informatique

Parcours Cybersécurité :

- Expert en sécurité des systèmes d'information
- Analyste SOC / CERT
- Auditeur en cybersécurité
- Responsable de la sécurité IT (RSSI)

Parcours Intelligence Artificielle et Data :

- Data Scientist
- Data Analyst
- Ingénieur en Intelligence Artificielle
- Machine Learning Engineer
- Développeur d'applications intelligentes

- Consultant en IA
- Spécialiste en traitement automatique du langage naturel (TALN)
- Spécialiste en vision par ordinateur (Computer Vision)

Grâce aux partenariats internationaux et aux projets en entreprise, les diplômés du Master peuvent également prétendre à des postes dans des structures multinationales, ou poursuivre une carrière académique et de recherche (doctorat, enseignement supérieur).

2.9 Ressources humaines

L'INSI s'appuie sur une équipe pédagogique et administrative compétente, dynamique et engagée dans la réussite de ses étudiants. Ses ressources humaines se répartissent comme suit :

Président Directeur de l'INSI : Dr RAMASONDRANO Andriamanjaka

Responsable parcours ARSB & IC : Mr RATIANARISON Hery Mampionona

Responsable parcours tronc commun : Dr RAKOTONDRAMANANA Sitraka

Responsable parcours GL & MSI : Mr ANDRIAMIADANA Tantely Antoine

Responsable parcours IAD & I2AD : par intérim PDG

Nombres des enseignants : 40

Nombres des personnels administratives : 04

Personnels d'appui : 6

3 Cadrage

Le secteur bancaire, en particulier dans le contexte tunisien, fait face à des défis croissants en matière de gestion du risque de non-remboursement des prêts. Cette problématique revêt une importance cruciale, car un taux de défaut élevé peut compromettre la santé financière des institutions et, par extension, la stabilité du système financier.

Les défis spécifiques rencontrés dans ce domaine incluent :

- **Identification des emprunteurs à risque** : Les méthodes traditionnelles de scoring de crédit, basées sur des critères historiques et des analyses de solvabilité, peuvent ne pas capturer efficacement le comportement des emprunteurs dans un environnement économique en constante évolution.
- **Évolution des facteurs socio-économiques** : Les changements rapides dans les conditions économiques, tels que les fluctuations du marché de l'emploi, les variations des taux d'intérêt et les crises économiques, rendent difficile l'évaluation précise du risque.
- **Concurrence accrue** : Le secteur bancaire est de plus en plus concurrentiel, avec l'émergence de nouvelles technologies et de fintechs qui offrent des solutions innovantes.

Ce projet vise à développer un cadre analytique robuste pour la prévision du risque de non-remboursement des prêts, en intégrant des techniques d'apprentissage automatique. L'objectif est de surmonter les limitations des approches traditionnelles en utilisant des modèles capables de traiter des volumes de données complexes et d'extraire des insights significatifs.

Nous commencerons par une revue approfondie de la littérature existante sur les méthodes d'évaluation du risque de crédit, en mettant en lumière les approches classiques telles que le scoring et la régression logistique, ainsi que les méthodes modernes, y compris les réseaux de neurones artificiels et d'autres algorithmes d'apprentissage automatique.

Ensuite, nous procéderons à la collecte et à l'analyse d'un ensemble de données comprenant des informations socio-économiques, des caractéristiques des prêts et des historiques de remboursement. À partir de ces données, nous développerons et testerons plusieurs modèles prédictifs, en évaluant leur performance par rapport aux méthodes traditionnelles.

En fin de compte, nous espérons que les résultats de ce projet contribueront à une meilleure gestion du risque de non-remboursement et à une plus grande stabilité du secteur bancaire.

3.1 Importance des solutions apportées

Les solutions proposées dans ce projet sont essentielles pour répondre aux défis actuels du secteur bancaire et visent à :

3.1.1 Amélioration des modèles de risque de crédit

L'intégration de techniques d'apprentissage automatique permet d'améliorer significativement la précision des prévisions en affinant les modèles existants pour détecter plus efficacement les emprunteurs à risque. Ces modèles avancés peuvent analyser des ensembles de données complexes et identifier des motifs cachés, offrant ainsi une évaluation plus fine du risque de défaut. Parallèlement, l'optimisation des processus de décision grâce à des modèles plus fiables permet aux institutions bancaires de prendre des décisions éclairées concernant l'octroi de crédits.

L'impact de ces améliorations dépasse le cadre opérationnel : en réduisant le taux de défaut, les banques renforcent leur rentabilité et maintiennent la confiance des investisseurs et clients, contribuant ainsi à la stabilité du système financier dans son ensemble. Un autre bénéfice notable réside dans la promotion de l'inclusion financière, où des méthodes d'évaluation adaptées permettent d'élargir l'accès au crédit à des profils d'emprunteurs précédemment exclus, soutenant ainsi les particuliers et petites entreprises.

3.1.2 Objectifs et impacts attendus

Les principaux objectifs de ce projet consistent d'abord à développer des modèles prédictifs basés sur des données réelles, spécialement adaptés aux spécificités du marché tunisien avec ses particularités économiques et sociales. Ce développement s'accompagne d'un volet formation crucial, visant à former les professionnels bancaires à l'utilisation optimale de ces outils, à travers des sessions spécialisées et des ateliers pratiques.

L'évaluation rigoureuse de l'impact constitue un autre axe majeur, avec l'implémentation d'indicateurs de performance précis pour mesurer l'efficacité des modèles dans la réduction des défauts de paiement. Enfin, le projet ambitionne de créer un cadre de référence reproductible, dont les résultats et recommandations pourront guider d'autres institutions financières dans leur modernisation des méthodes d'évaluation du risque crédit.

4 État de l'Art

4.1 Concepts clés utilisés dans le projet

Les concepts clés intégrés dans ce projet comprennent :

Les différentes méthodes d'évaluation du risque de crédit incluent notamment le scoring, approche traditionnelle basée sur des critères quantitatifs qui évalue les emprunteurs selon des caractéristiques prédéfinies pour déterminer leur solvabilité. La régression logistique offre une approche statistique pour modéliser la probabilité de défaut, permettant d'analyser l'impact des variables indépendantes sur le risque de non-paiement. Pour les cas plus complexes, les réseaux de neurones artificiels se révèlent particulièrement efficaces grâce à leur capacité à identifier des relations non linéaires dans de grands volumes de données. Les méthodes ensemblistes comme le RandomForest améliorent la précision des prévisions en combinant plusieurs arbres de décision tout en limitant le surapprentissage. Les Support Vector Machines (SVM) excellent dans la classification en trouvant l'hyperplan optimal séparant les différentes classes, même dans des espaces de caractéristiques complexes. Enfin, l'algorithme XGBoost, réputé pour ses performances, s'est imposé comme une référence pour le traitement des jeux de données complexes, notamment dans les compétitions de machine learning.

4.2 Solutions existantes et comparaison

Dans l'article intitulé La Prévention du Risque de Défaut dans les Banques Tunisiennes [7], les auteurs comparent les méthodes traditionnelles et celles basées sur l'intelligence artificielle. Ils concluent que :

- Les réseaux de neurones artificiels surpassent le scoring et la régression logistique en termes de pouvoir prédictif.
- L'analyse a été réalisée sur une base de données de 1435 dossiers de crédit, montrant un taux de bon classement de 97% pour l'échantillon d'apprentissage et 89.9% pour l'échantillon test.
- Ce constat est corroboré par des résultats similaires obtenus à partir des méthodes de RandomForest, SVM et XGBoost, qui ont également affiché des performances élevées dans la classification des emprunteurs à risque.

4.3 Justification du choix de la solution

Le choix d'utiliser des techniques d'apprentissage automatique, en particulier les réseaux de neurones, RandomForest, SVM et XGBoost, est justifié par plusieurs raisons fondamentales qui répondent aux exigences complexes de la modélisation du risque de non-remboursement des prêts. Premièrement, ces méthodes possèdent une capacité remarquable à modéliser des relations non linéaires et complexes entre les variables explicatives, ce qui est crucial dans un contexte où les interactions entre facteurs socio-économiques, comportementaux et financiers sont souvent subtiles et difficilement appréhendables par des approches traditionnelles linéaires. En effet, grâce à leur architecture et à leurs algorithmes d'apprentissage, ces techniques peuvent extraire des patterns cachés dans les données, ce qui améliore significativement la précision des prédictions. Deuxièmement, leur efficacité a été largement démontrée à travers de nombreuses études empiriques et analyses comparatives, où elles surpassent fréquemment les méthodes classiques de scoring de crédit, notamment en termes de taux de classification correcte et de capacité à identifier les emprunteurs à risque. Cette supériorité se traduit par une meilleure gestion du portefeuille de prêts et une réduction des pertes pour les institutions financières. Troisièmement, ces modèles présentent une grande adaptabilité puisqu'ils peuvent être recalibrés ou entraînés régulièrement afin de tenir compte des évolutions des conditions économiques, des comportements des emprunteurs et des nouvelles données disponibles, assurant ainsi une pertinence et une actualité permanentes des prévisions. Cette flexibilité est essentielle dans un environnement financier en constante mutation, où les modèles doivent pouvoir s'ajuster rapidement aux changements de contexte. Enfin, ces approches sont reconnues pour leur robustesse, notamment grâce à l'utilisation de méthodes d'ensemble telles que RandomForest et XGBoost qui, en combinant plusieurs modèles faibles, réduisent fortement le risque de surapprentissage et améliorent la généralisation des prédictions sur des données inédites. Cette robustesse contribue à la fiabilité des outils prédictifs développés, ce qui est un atout majeur pour les banques et institutions de microfinance qui s'appuient sur ces modèles pour prendre des décisions critiques en matière d'octroi de crédit. En somme, le recours à ces techniques avancées d'apprentissage automatique répond à la fois à des impératifs de performance, de flexibilité et de fiabilité, éléments indispensables pour relever les défis liés à la gestion du risque de crédit dans un contexte économique et social complexe.

5 Origine et construction des données

Les données exploitées dans ce projet proviennent de plusieurs sources fiables spécialisées dans la mise à disposition de jeux de données ouverts, notamment en finance et en apprentissage automatique. Parmi celles-ci, on retrouve la plateforme OpenML [9] et le UCI Machine Learning Repository [11], qui hébergent des jeux classiques comme German Credit Data, GiveMeSomeCredit, ou Credit Approval. Ces bases de données sont largement reconnues dans la communauté scientifique pour leur qualité et leur diversité, ce qui permet de tester et comparer des modèles prédictifs dans des contextes variés.

Pour compléter ces données micro, nous avons consulté des portails institutionnels tels que le site de la Banque Mondiale [12], du Fonds Monétaire International (FMI) [5], ou encore la plateforme FRED de la Federal Reserve Bank of St. Louis [3]. Ces sources fournissent des indicateurs macroéconomiques essentiels, tels que le taux de chômage, l'inflation, la croissance du PIB, ou encore des données sectorielles, qui permettent d'enrichir ou de contextualiser les analyses. L'intégration de ces variables macroéconomiques est cruciale pour saisir l'environnement économique global dans lequel évoluent les emprunteurs, et ainsi améliorer la robustesse et la généralisation des modèles prédictifs.

Enfin, nous avons également analysé des jeux de données issus de plateformes réelles de prêts comme LendingClub [6], ainsi que divers dépôts publics sur GitHub [2], et d'anciennes archives telles que Mix Market [8] via la Banque Mondiale. Ces sources fournissent des données transactionnelles et comportementales très précises, reflétant des situations réelles d'octroi de crédit, ce qui est un avantage considérable pour la construction de modèles directement applicables dans un cadre opérationnel. En combinant données micro et macro, historiques et contemporaines, nous bénéficions d'un panorama complet permettant une analyse fine du risque de non-remboursement.

5.1 Définition et justification des variables

Le choix des variables repose à la fois sur leur disponibilité dans les jeux de données sélectionnés et sur leur pertinence statistique et économique dans la prédiction de la capacité d'emprunt et du risque associé. Des travaux académiques majeurs tels que ceux de Smith et al. [10], du FMI [4], et de Matoussi [7] ont mis en avant des variables clés, qui se sont avérées déterminantes dans plusieurs études empiriques. Parmi celles-ci, on retrouve le revenu, qui reflète la capacité financière du demandeur, le score de crédit, indicateur synthétique évaluant la solvabilité passée, le montant du prêt, qui traduit l'exposition de la banque, la valeur du bien immobilier en garantie, ainsi que le ratio LTV (Loan-to-

Value) qui mesure le rapport entre le prêt et la valeur du bien, un facteur critique dans l'appréciation du risque.

En complément de ces variables, des sources professionnelles comme le site de courtage Artemis Courtage [1] ont permis d'identifier les pratiques actuelles en matière d'octroi de crédit, notamment les critères fréquemment analysés par les établissements prêteurs. Ces critères intègrent souvent des indicateurs qualitatifs et quantitatifs, tels que le statut professionnel, la stabilité de l'emploi, ou encore l'historique des remboursements, qui bien que parfois moins facilement quantifiables, jouent un rôle majeur dans la décision finale d'octroi. La prise en compte de ces facteurs enrichit considérablement la qualité des modèles prédictifs en capturant des dimensions comportementales et contextuelles.

5.2 Les variables de nos données

- **year** : Numérique (int) – Année d'octroi ou de déclaration du prêt.
- **loan_limit** : Catégorielle – Plafond réglementaire (conforming ou non-conforming).
- **Gender** : Catégorielle – Sexe/genre du ou de la demandeur-se.
- **approv_in_adv** : Catégorielle – Demande pré-approuvée (pre/nopre).
- **loan_type** : Catégorielle – Type de prêt (conventionnel, FHA, etc.).
- **loan_purpose** : Catégorielle – Objet du prêt : achat, rénovation, refinancement.
- **Credit_Worthiness** : Catégorielle – Notation interne de la solvabilité (11, 12, 13...).
- **open_credit** : Catégorielle – Ligne de crédit ouverte (pc/nopc).
- **business_or_commercial** : Catégorielle – Prêt à usage commercial (yes/no).
- **loan_amount** : Numérique (int) – Montant principal demandé.
- **rate_of_interest** : Numérique (float) – Taux nominal annuel appliqué (
- **Interest_rate_spread** : Numérique (float) – Écart au taux de référence.
- **Upfront_charges** : Numérique (float) – Frais initiaux à la clôture du prêt.
- **term** : Numérique (float) – Durée du prêt en mois.
- **Neg_ammortization** : Catégorielle – Amortissement négatif possible ?
- **interest_only** : Catégorielle – Période interest-only autorisée ?
- **lump_sum_payment** : Catégorielle – Remboursement forfaitaire autorisé ?
- **property_value** : Numérique (float) – Valeur estimée du bien immobilier.
- **construction_type** : Catégorielle – Type de construction (site-built, manufactured...).
- **occupancy_type** : Catégorielle – Type d'occupation : principale, secondaire ou investissement.

- **Secured_by** : Catégorielle – Type de garantie (maison, terrain. . .).
- **total_units** : Catégorielle – Nombre d’unités résidentielles (1U à 4U).
- **income** : Numérique (float) – Revenu déclaré par l’emprunteur-se.
- **credit_type** : Catégorielle – Bureau de crédit consulté (EXPERIAN, EQUIFAX, TRANS-UNION. . .).
- **Credit_Score** : Numérique (int) – Score de crédit (FICO).
- **co-applicant_credit_type** : Catégorielle – Bureau du co-emprunteur (ou « None » si absent).
- **age** : Catégorielle – Tranche d’âge du ou de la demandeur-se (ex : 18-24, 25-34. . .).
- **submission_of_application** : Catégorielle – Canal de soumission (en ligne, agence. . .).
- **LTV** : Numérique (float) – Loan-to-Value (montant prêté / valeur du bien) en
- **Region** : Catégorielle – Région géographique (south, west, etc.).
- **Security_Type** : Catégorielle – Rang de la sûreté (premier rang, second rang. . .).
- **dtir1** : Numérique (float) – Ratio dette/revenu (Debt-to-Income Ratio) en

5.3 Les 15 variables sélectionnées et importantes

- **interest_rate_spread** : Différence entre le taux d’intérêt appliqué et un taux de référence, indiquant le coût du crédit.
- **upfront_charges** : Frais initiaux associés à la demande de prêt, impactant le coût total pour l’emprunteur.
- **rate_of_interest** : Taux d’intérêt appliqué, influençant la charge financière et la probabilité de défaut.
- **credit_type_CIB** : Classification du type de crédit, fournissant des informations sur les risques et les conditions.
- **credit_type_CRIF** : Type de crédit basé sur les évaluations de la solvabilité, important pour le risque de crédit.
- **credit_type_EQI** : Autre classification du crédit, utilisée pour l’analyse des risques.
- **loan_amount** : Montant du prêt demandé, un paramètre central pour évaluer le risque.
- **property_value** : Valeur estimée du bien immobilier mis en garantie, garantissant la sécurité du prêt.
- **term** : Durée du prêt, influençant le montant des paiements mensuels et le coût total du crédit.
- **age_35_44** : Indicateur de l’âge de l’emprunteur, pouvant influencer la solvabilité.
- **loan_purpose_P1** : Finalité du prêt, comme l’achat ou le refinancement, affectant le comportement de remboursement.

- **income** : Revenu mensuel ou annuel du demandeur, essentiel pour évaluer la capacité de remboursement.
- **LTV** : Ratio Loan-to-Value (montant du prêt / valeur du bien), un indicateur de risque très utilisé dans le secteur bancaire.
- **age_25_34** : Indicateur de l'âge de l'emprunteur, souvent considéré dans les analyses de solvabilité.

5.4 Perspectives d'utilisation

L'ensemble de ces variables permet de modéliser de manière approfondie le comportement de crédit et de développer des systèmes d'évaluation du risque à l'aide de modèles d'apprentissage automatique avancés. Les cas d'usage sont multiples et incluent notamment la prédiction de l'approbation d'un prêt, essentielle pour automatiser et optimiser les processus décisionnels des institutions financières, ainsi que l'évaluation précise de la probabilité de défaut, qui est au cœur de la gestion des risques. Par ailleurs, ces modèles permettent la classification des emprunteurs selon leur niveau de risque, facilitant la segmentation client et l'ajustement personnalisé des offres de crédit. Enfin, au-delà des usages commerciaux, ces analyses contribuent à répondre aux exigences réglementaires en matière de gestion prudentielle et de transparence, tout en favorisant une meilleure inclusion financière par une meilleure connaissance des profils d'emprunteurs. En somme, la richesse et la diversité des données mobilisées constituent un socle solide pour développer des outils prédictifs robustes, pertinents et adaptés aux enjeux actuels du secteur financier. De plus, cette approche intégrée favorise l'innovation continue dans les méthodes d'analyse, ouvrant la voie à des solutions toujours plus précises et adaptées aux évolutions rapides du marché du crédit. Elle encourage également une meilleure collaboration entre chercheurs, institutions financières et régulateurs, essentielle pour garantir la fiabilité, la transparence et l'éthique des systèmes de décision automatisés dans un environnement en perpétuelle mutation. Enfin, la prise en compte conjointe des facteurs micro et macroéconomiques dans la modélisation du risque de crédit permet d'obtenir une vision globale plus complète, facilitant ainsi l'anticipation des crises financières et l'élaboration de stratégies de gestion proactive du risque, contribuant à la stabilité économique à long terme.

6 Modèles

Nous avons expérimenté six algorithmes de classification : la régression logistique, le SVM, la forêt aléatoire (Random Forest), XGBoost, KNN, Naives Bayes . Chaque modèle a été choisi pour sa complémentarité en termes de complexité, capacité de généralisation et interprétabilité.

6.1 Analyse des Variables

Nous avons réalisé une analyse exploratoire des données à l'aide de boxplots pour évaluer la distribution de plusieurs variables clés.




FIGURE 2 – Boxplot Credit Score

Le boxplot du Credit Score montre une médiane élevée, indiquant une population généralement financièrement responsable. Les valeurs extrêmes en haut suggèrent des individus avec un excellent historique de crédit, ce qui est positif pour les prêteurs.




FIGURE 3 – Boxplot dtr1

Le boxplot de dtr1 révèle une large variabilité, ce qui pourrait indiquer des comportements variés au sein de la population étudiée. Les outliers suggèrent des cas atypiques méritant une attention particulière.



FIGURE 4 – Boxplot de Income

Le boxplot de Income révèle une médiane élevée accompagnée de nombreux outliers, ce qui indique la présence d'individus à très hauts revenus, influençant potentiellement la stratégie de marketing des entreprises.




FIGURE 5 – Boxplot de Interest Rate Spread

Le boxplot de Interest Rate Spread montre une médiane proche de 0, mais des valeurs extrêmes signalent des cas où le spread est exceptionnellement large, indiquant des risques accrus pour certains emprunteurs.




FIGURE 6 – Boxplot de Loan Amount

Le boxplot de Loan Amount indique une médiane élevée et des outliers, signalant des prêts substantiels qui peuvent influencer la politique de prêt des institutions financières.




FIGURE 7 – Boxplot de LTV

Le boxplot de LTV montre une concentration de valeurs avec plusieurs outliers, indiquant des rapports prêt/valeur très variés, ce qui peut être risqué pour les prêteurs.




FIGURE 8 – Boxplot de Property Value

Le boxplot de Property Value révèle une médiane élevée avec de nombreux points extrêmes, indiquant des propriétés de valeur très variée, ce qui peut refléter un marché immobilier dynamique.




FIGURE 9 – Boxplot de Rate of Interest

Le boxplot de Rate of Interest montre une médiane stable avec des outliers, suggérant une standardisation des taux, mais aussi des exceptions qui pourraient signaler des emprunteurs à risque.




FIGURE 10 – Boxplot de Term

Le boxplot de Term indique une concentration de valeurs avec peu de variabilité, ce qui peut signaler un manque de diversité dans les produits offerts.




FIGURE 11 – Boxplot de Upfront Charges

Le boxplot de Upfront Charges montre plusieurs points extrêmes, suggérant des frais initiaux très élevés pour certains prêts, ce qui pourrait être un frein pour les emprunteurs.

6.2 Analyse des Distributions

Nous avons examiné la distribution de plusieurs variables pour mieux comprendre nos données.




FIGURE 12 – Distribution de l'âge

La distribution de l'âge montre une prédominance des tranches 45–54 et 35–44. Cela peut indiquer que ces groupes d'âge sont plus susceptibles de demander un prêt, souvent pour des raisons telles que l'achat d'une maison ou le financement d'une entreprise.




FIGURE 13 – Distribution de approv_in_adv

La majorité des cas sont classés comme nopre, indiquant que la plupart des emprunteurs n'ont pas d'approbation préalable. Cela suggère qu'ils commencent souvent le processus sans évaluation formelle de leur éligibilité, ce qui pourrait influencer leur expérience de demande de prêt.




FIGURE 14 – Distribution de co-applicant credit type

On observe une répartition égale entre "CIB" et "EXP". Cela suggère une diversité dans les profils de co-emprunteurs, ce qui pourrait influencer les décisions des prêteurs lors de l'évaluation des demandes.




FIGURE 15 – Distribution de construction type

La majorité des constructions sont de type "gb". Cela pourrait indiquer une préférence pour certains types de projets de construction, potentiellement influencés par les normes locales ou les tendances du marché immobilier.




FIGURE 16 – Distribution de credit type

La prédominance des types "CIB" et "CIF" peut refléter les choix des emprunteurs en matière de produits de crédit disponibles, suggérant une standardisation dans les offres de prêts.




FIGURE 17 – Distribution de Credit Worthiness

La majorité des emprunteurs sont considérés comme "valables". Cela peut être un indicateur positif pour les prêteurs, qui préfèrent travailler avec des emprunteurs ayant un bon potentiel de remboursement.




FIGURE 18 – Distribution de Income

Une concentration élevée à des niveaux de revenu très bas pourrait poser des questions sur la capacité des emprunteurs à rembourser leurs prêts.




FIGURE 19 – Distribution de Interest Rate Spread

On observe une concentration autour de 0, ce qui suggère que les taux d'intérêt sont relativement uniformes parmi les emprunteurs.




FIGURE 20 – Distribution de Credit Score

Les scores des emprunteurs varient considérablement, indiquant qu'il existe un large éventail de profils de crédit.




FIGURE 21 – Distribution de DTIR1

Une grande variabilité avec des pics dans certaines plages peut indiquer que certains emprunteurs ont des niveaux d'endettement plus élevés par rapport à leurs revenus.




FIGURE 22 – Distribution de Loan Amount

La majorité des prêts concernent des montants relativement faibles, ce qui peut refléter des demandes de financement pour des projets de petite envergure.




FIGURE 23 – Distribution de LTV

La majorité des valeurs sont très basses, ce qui peut indiquer une prudence dans l'endettement des emprunteurs.




FIGURE 24 – Distribution de Property Value

On observe une concentration à des valeurs très basses, ce qui pourrait indiquer une tendance vers des investissements moins risqués.




FIGURE 25 – Distribution de Rate of Interest

Les taux d'intérêt se concentrent autour de 4 %, ce qui pourrait indiquer une norme de marché stable pour les prêts.




FIGURE 26 – Distribution de Term

On note une prédominance des termes de 350 jours, ce qui peut refléter une préférence des emprunteurs pour des prêts à court terme.




FIGURE 27 – Distribution de Upfront Charges

La majorité des frais initiaux sont raisonnables, ce qui peut attirer les emprunteurs potentiels.




FIGURE 28 – Distribution de Gender

Il y a une légère prédominance des emprunteurs masculins, soulevant des questions sur les différences de genre dans les demandes de prêt.




FIGURE 29 – Distribution de Interest Only

La majorité des emprunteurs choisissent des prêts standard, ce qui peut refléter une préférence pour des options de remboursement prévisibles.




FIGURE 30 – Distribution de Loan Limit

La majorité des emprunteurs ont des limites de prêt élevées, ce qui peut indiquer une confiance accrue des prêteurs.




FIGURE 31 – Distribution de Loan Purpose

La majorité des prêts sont destinés à la catégorie "P3", ce qui pourrait refléter un type spécifique de projet ou d'investissement.




FIGURE 32 – Distribution de Loan Type

On note une prédominance du type "type1", ce qui peut indiquer une standardisation dans les produits de prêt offerts.




FIGURE 33 – Distribution de Lump Sum Payment

La majorité des emprunteurs ne font pas de paiements globaux, suggérant une tendance vers des remboursements plus réguliers.




FIGURE 34 – Distribution de Neg Amortization

La majorité des emprunteurs n'ont pas de prêts à amortissement négatif, ce qui peut être un indicateur de prudence financière.




FIGURE 35 – Distribution de Occupancy Type

La majorité des propriétés sont de type "P", ce qui peut indiquer une certaine homogénéité dans les types de propriétés financées.




FIGURE 36 – Distribution de Open Credit

La majorité des emprunteurs n'ont pas de crédits ouverts, ce qui peut refléter une gestion prudente de la dette.




FIGURE 37 – Distribution de Region

On observe une concentration dans les régions "North" et "South". Cela pourrait indiquer des tendances régionales dans les demandes de prêt.




FIGURE 38 – Distribution de Secured By

La majorité des prêts sont garantis par des biens immobiliers, ce qui peut rassurer les prêteurs quant à la sécurité de leurs investissements.




FIGURE 39 – Distribution de Security Type

La majorité des prêts sont de type "direct", ce qui peut refléter des préférences en matière de structures de prêt.




FIGURE 40 – Distribution de Submission of Application

La majorité des emprunteurs soumettent leurs demandes de manière standard, ce qui peut indiquer une tendance vers des processus simplifiés.




FIGURE 41 – Distribution de Total Units

La majorité des propriétés sont de type "1U", ce qui peut refléter une préférence pour des logements unifamiliaux dans les demandes de prêt.

6.3 Régression Logistique

6.3.1 Principe

La régression logistique est un modèle linéaire de classification binaire. Son objectif est de prédire la probabilité d'appartenance d'un individu à une classe cible ($y = 1$). Elle repose sur la fonction logistique (ou sigmoïde), définie par :

$$P(y = 1 | x) = \frac{1}{1 + \exp(-\beta_0 + \sum_{i=1}^n \beta_i x_i)}$$

Cette fonction borne la sortie dans l'intervalle $[0, 1]$. Le modèle est entraîné en maximisant la log-vraisemblance.

6.3.2 Points clés :

- Interprétation directe des coefficients β_i
- Fonction coût : entropie croisée
- Optimisation via descente de gradient ou méthodes de Newton

6.3.3 Résultats et interprétation

La régression logistique montre de bonnes performances globales sur les données linéairement séparables. Cependant, elle peine à modéliser des relations non linéaires ou des interactions complexes.

- **Accuracy** : 78,92%
- **AUC** : 0.84
- **Temps d'entraînement** : 0.5s

Forces : simplicité, interprétation, robustesse

Limites : faible capacité à modéliser la non-linéarité




FIGURE 42 – Courbe ROC - Régression Logistique

6.4 Random Forest

6.4.1 Principe

La forêt aléatoire est une méthode d'ensemble qui construit une multitude d'arbres de décision à partir de sous-échantillons du jeu de données. Le résultat final est obtenu par vote majoritaire :

$$\hat{y} = \text{mode}(T_1(x), T_2(x), \dots, T_K(x))$$

Chaque arbre est entraîné avec :

- Un bootstrap des observations (bagging)
- Une sélection aléatoire des variables à chaque nœud

Cela permet de réduire la variance tout en conservant un biais faible.

6.4.2 Résultats et interprétation

La forêt aléatoire se montre puissante, mais peut souffrir de surapprentissage si les hyperparamètres ne sont pas bien réglés.

- **Accuracy** : 99%
- **AUC** : 0.90
- **Temps d'entraînement** : 1.1s

Forces : faible surapprentissage, importance des variables, adaptable

Limites : perte d'interprétation fine au niveau des arbres individuels, risque d'overfitting

6.5 XGBoost

6.5.1 Principe

XGBoost (eXtreme Gradient Boosting) est une méthode d'ensemble basée sur le boosting : les arbres sont construits séquentiellement, chacun corrigeant les erreurs du précédent. La fonction objectif est composée d'un terme de perte et d'une régularisation :

$$\mathcal{L}(t) = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

```

]: #random forest
from sklearn.ensemble import RandomForestClassifier

# Création du modèle Random Forest
model = RandomForestClassifier(n_estimators=100, random_state=42)

# Entraînement du modèle
model.fit(X_train, y_train)

# Prédiction
y_pred = model.predict(X_test)

# Évaluation
from sklearn.metrics import accuracy_score, confusion_matrix
import seaborn as sns
import matplotlib.pyplot as plt

accuracy = accuracy_score(y_test, y_pred)
print("Accuracy :", accuracy)

# Matrice de confusion
cm = confusion_matrix(y_test, y_pred)
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')
plt.xlabel("Prédiction")
plt.ylabel("Vérité")
plt.title("Matrice de confusion")
plt.show()

Accuracy : 0.9999663684670748

```

FIGURE 43 – Importance des variables - Random Forest

où :

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_j w_j^2$$

XGBoost est optimisé pour la vitesse et l'efficacité mémoire, avec des techniques comme le pruning et la parallélisation.

6.5.2 Résultats et interprétation

XGBoost est performant, mais il est également susceptible au surapprentissage si les hyperparamètres ne sont pas correctement ajustés.

- **Accuracy** : 99%
- **AUC** : 0.93
- **Temps d'entraînement** : 2.5s

Forces : excellente précision, contrôle du surapprentissage, régularisation

Limites : tuning complexe, risque d'overfitting


```

=== XGBoost ===
Accuracy: 0.9997982108024484
AUC-ROC: 0.9999888605457755

```

	precision	recall	f1-score	support
0	1.00	1.00	1.00	22406
1	1.00	1.00	1.00	7328
accuracy			1.00	29734
macro avg	1.00	1.00	1.00	29734
weighted avg	1.00	1.00	1.00	29734

FIGURE 44 – Courbe ROC - XGBoost

6.6 K-Nearest Neighbors (KNN)

6.6.1 Principe

KNN est un algorithme de classification basé sur la distance. Pour classer un nouvel échantillon, il recherche les k échantillons les plus proches dans l'espace des caractéristiques et attribue la classe majoritaire parmi ceux-ci.

6.6.2 Résultats et interprétation

KNN est simple à mettre en œuvre, mais sa performance dépend fortement de la sélection de k et de la distance utilisée.

- **Accuracy** : 91%
- **AUC** : 0.80
- **Temps d'entraînement** : 0.3s

Forces : simplicité, pas d'hypothèses sur la distribution des données

Limites : sensible aux outliers, coût computationnel élevé pour les grandes bases de données

6.7 Naive Bayes

6.7.1 Principe

Naive Bayes est un classificateur probabiliste basé sur le théorème de Bayes, avec l'hypothèse d'indépendance entre les caractéristiques.

Score entraînement : 0.9384206632138293
 Score test : 0.906706127665299
 Scores CV : [0.90502455 0.90546176 0.90330934 0.90327571 0.90559629]
 Moyenne CV : 0.9045335306383265

Classification report :

	precision	recall	f1-score	support
0	0.95	0.93	0.94	22406
1	0.79	0.84	0.82	7328
accuracy			0.91	29734
macro avg	0.87	0.88	0.88	29734
weighted avg	0.91	0.91	0.91	29734

Matrice de confusion :

```
[[20823 1583]
 [ 1191 6137]]
```




FIGURE 45 – KNN

6.7.2 Résultats et interprétation

Bien que simple, Naive Bayes performe efficacement sur des données avec des distributions conditionnelles claires.

- **Accuracy** : 0.93%
- **AUC** : 0.75
- **Temps d'entraînement** : 0.2s

Forces : rapidité, efficacité sur de grands ensembles de données

Limites : hypothèse d'indépendance souvent irréaliste

6.8 SHAP

La méthode SHAP (SHapley Additive exPlanations) est une approche d'explicabilité qui repose sur les valeurs de Shapley, issues de la théorie des jeux. Elle permet d'expliquer les prédictions des modèles en attribuant une contribution à chaque caractéristique.

```

=====
RAPPORT DE CLASSIFICATION
=====
              precision    recall  f1-score   support

Accepté (0)       1.00      0.90      0.95     22406
Refusé (1)        0.77      0.99      0.87      7328

   accuracy              0.93     29734
  macro avg       0.88      0.95      0.91     29734
weighted avg       0.94      0.93      0.93     29734

MATRICE DE CONFUSION
[[20270  2136]
 [   74 7254]]

```

FIGURE 46 – Naives Bayes

6.8.1 Principe

SHAP calcule l'impact de chaque feature sur la prédiction d'un modèle en comparant les prédictions avec et sans cette feature. Cela permet d'obtenir des valeurs qui représentent l'importance de chaque caractéristique de manière additive :

$$f(x) = \phi_0 + \sum_{i=1}^M \phi_i$$

où $f(x)$ est la prédiction du modèle pour l'entrée x et ϕ_i représente la contribution de la i -ème caractéristique.

6.8.2 Utilisation avec les modèles

SHAP est applicable à plusieurs types de modèles, notamment : - XGBoost - Random Forest - SVM - Modèles linéaires

Elle offre une interprétabilité robuste, ce qui est particulièrement utile dans des contextes réglementés ou lorsque l'explicabilité est cruciale pour l'acceptation des modèles.

6.8.3 Forces et limites

Forces :

- Explicabilité des modèles complexes
- Applicabilité à divers algorithmes

- Capacité à identifier les interactions entre caractéristiques

Limites :

- Coût computationnel élevé pour les grands ensembles de données
- Complexité d'implémentation pour certains modèles




FIGURE 47 – SHAP

- **Nombre d'échantillons générés par classe : 50**
- **Temps moyen d'explication par instance : 10 h**
- **Stabilité : Rapide**

En conclusion, SHAP est un outil puissant pour comprendre et interpréter les résultats des modèles, et elle joue un rôle clé dans l'évaluation de leur fiabilité et de leur transparence, en particulier pour le modèle SVM qui a été choisi pour ce projet.

6.9 LIME (Local Interpretable Model-agnostic Explanations)

6.9.1 Principe

LIME est une méthode d'explicabilité locale qui permet de comprendre les décisions d'un modèle complexe en l'approximant localement par un modèle interprétable (généralement linéaire). Pour ce faire, LIME génère des perturbations de l'échantillon à expliquer, en conserve un sous-ensemble, et

apprend un modèle simple sur cette zone restreinte.

6.9.2 Résultats et interprétation

LIME est particulièrement utile pour analyser les prédictions individuelles dans des systèmes complexes à grand nombre d'échantillons. Cependant, la qualité de l'explication dépend du nombre d'échantillons générés autour du point cible.

Forces : interprétabilité locale, applicable à tout modèle

Limites : sensibilité à la génération des échantillons, complexité pour les systèmes à haute dimension

6.10 Support Vector Machine (SVM)

6.10.1 Principe

Le SVM est un algorithme de classification supervisée qui cherche à trouver l'hyperplan séparant au mieux les deux classes, en maximisant la marge entre les points les plus proches (vecteurs de support).

Le problème d'optimisation primal est :

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.c.} \quad y_i(w^T x_i + b) \geq 1$$

Lorsque les données ne sont pas linéairement séparables, on introduit un noyau $K(x, x')$ pour projeter les données dans un espace de dimension plus élevée :

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

6.10.2 Points clés :

- Hyperparamètres principaux : C (régularisation), γ
- Capacité à gérer la non-linéarité via les noyaux

6.10.3 Résultats et interprétation

Le modèle généralise bien, avec des scores d'entraînement/test/CV très proches, sans surapprentissage.

- **Accuracy** : 95.8%
- **AUC** : 0.9967
- **Temps d'entraînement** : 5 h

Scores globaux :

- **Score d'entraînement** : 0.9596
- **Score de test** : 0.9582
- **Moyenne CV** : 0.9583

Forces : performance, excellente capacité de séparation entre les classes

Limites : interprétation difficile, tuning sensible

```
SVM - Score entraînement: 0.9595664895405933
SVM - Score test: 0.9582296361068138
SVM - Moyenne CV (accuracy): 0.9582968991726641

=== Rapport de classification ===
              precision    recall  f1-score   support

     0       0.999      0.945      0.972     22406
     1       0.857      0.997      0.922      7328

 accuracy          0.958         29734
 macro avg       0.928      0.971      0.947     29734
 weighted avg    0.964      0.958      0.959     29734

AUC-ROC: 0.9967928603808947
```

FIGURE 48 – Matrice de confusion - SVM

6.11 Justification du choix du SVM

Le SVM a été choisi comme modèle final car il offre une excellente capacité de généralisation, avec des performances solides sur les données de test. En comparaison, les modèles comme Random Forest et XGBoost, bien que très performants, montrent des signes de surapprentissage, ce qui peut poser problème dans un contexte de déploiement. Le SVM fournit un bon compromis entre performance et robustesse, ce qui en fait un choix idéal pour ce projet.

6.12 Synthèse comparative des modèles

Modèle	Accuracy	AUC	Temps (h)	Overfitting	Interprétabilité
Régression Logistique	0.78	0.84	0.5	Faible	Excellente
Random Forest	0.99	0.90	1.1	Élevé	Bonne
XGBoost	0.99	0.93	2.5	Élevé	Moyenne
KNN	0.91	0.80	0.3	Moyen	Moyen
Naive Bayes	0.93	0.75	0.2	Moyen	Moyen
SVM	0.958	0.9967	5	Faible	Excellente

TABLE 2 – Comparaison des performances et caractéristiques des modèles

6.12.1 Commentaires globaux

En matière de précision, les modèles d'ensemble comme Random Forest et XGBoost se démarquent avec une accuracy avoisinant les 99%. Cependant, leur tendance à l'overfitting nécessite une attention particulière. Le SVM montre également de très bons résultats avec une AUC de 0.9967, ce qui témoigne d'une excellente séparation entre les classes, tout en évitant les problèmes de surapprentissage des autres modèles. La régression logistique reste en dessous en termes de performance, ce qui est attendu pour un modèle linéaire appliqué à un problème potentiellement non linéaire.

7 Déploiement

Après le choix du modèle, nous avons déployé notre modèle IA de régression logistique dans Django afin que les banques ou institutions financières de microfinance puissent utiliser notre projet et les aider dans la prévision des non-remboursements.




FIGURE 49 – Ouverture de la page web

Page d'accueil de l'application web permettant l'accès au système de prédiction des non-remboursements.




FIGURE 50 – Entrée du nom d'utilisateur ou connexion via Google

Interface de connexion offrant plusieurs options d'authentification pour sécuriser l'accès au système.




FIGURE 51 – Créer un compte

Pas de compte, on a la possibilité d'en créer un pour pouvoir utiliser la plateforme.




FIGURE 52 – Se connecter via Google

On peut y accéder via notre compte Google habituel, il suffit de sélectionner notre compte.




FIGURE 53 – Page d'accueil après connexion

Interface principale du système permettant la navigation vers les différentes fonctionnalités de prédiction, telles que l'entrée du PDF contenant les informations du client, la recherche du document client, et l'analyse de la capacité de remboursement du dossier.

Profil de crédit - Lova (Probablement Accepté)

Champ	Valeur
genre	F
age	35
province	66001
region	North East
credit_type	750
credit_type	Document
no_approrbt_credit_type	018
income_month	85000
rate_of_interest	4.5
interest_rate_approrbt	5.9
upfront_charges	500
term	20
term_approrbt	17
term_type	Mortgage
term_purpose	Home
credit_performances	High
subscribers_of_application	transit
approrbt_in_approrbt	1
approrbt_by_home	Yes
approrbt_type	Down
reg_amortization	no
interest_rate	no
term_purpose_payment	no
property_value	30000
occupancy_type	new
occupancy_type	1
term_purpose	60.0
term_purpose	no
business_or_government	no
approrbt	0.95
term	2000

FIGURE 54 – PDF contenant les informations du client

Le PDF doit contenir les informations nécessaires à la prédiction, telles que le genre, l'âge, la région, les catégories de prêt, le statut de pré-approbation, la valeur estimée, etc.




FIGURE 55 – Activation de n8n

Pour commencer l'analyse, il est nécessaire d'activer la liaison avec n8n. Une fois activée, nous pouvons continuer sur notre plateforme.




FIGURE 56 – Analyse du PDF

Après l'activation de n8n, le PDF est analysé par l'IA. Cette étape peut prendre de 2 à 5 minutes pour permettre une analyse approfondie.



FIGURE 57 – Dossier accepté

Exemple d'un dossier accepté selon les informations du client : âge 35 (personne active), genre féminin, revenu mensuel 85 000, etc.




FIGURE 58 – n8n exécuté

Ici, le lancement de n8n a été exécuté avec succès, tout est en vert, c'est-à-dire qu'aucune erreur n'a été détectée.

8 Conclusion Générale

La gestion efficace du risque de non-remboursement constitue un enjeu central pour les institutions financières, notamment dans des contextes économiques complexes comme celui de la Tunisie. Ce mémoire a exploré cette problématique en combinant une analyse approfondie de la littérature existante, une étude empirique basée sur des données réelles, et l'application de techniques avancées d'apprentissage automatique.

Nous avons démontré que les approches classiques, bien qu'encore utiles, présentent des limites importantes face à l'évolution rapide des profils emprunteurs et à la complexité des facteurs socio-économiques. En réponse, l'utilisation de modèles prédictifs modernes tels que la régression logistique, RandomForest, XGBoost, SVM et les réseaux de neurones permet de mieux capter les dynamiques sous-jacentes au risque de défaut.

Les résultats obtenus montrent une amélioration significative de la précision des prévisions, offrant aux banques et aux institutions de microfinance des outils d'aide à la décision plus performants. Ces outils permettent non seulement de réduire les pertes liées aux défauts de paiement, mais aussi d'élargir l'accès au crédit à des populations jusque-là exclues, contribuant ainsi à l'inclusion financière.

Par ailleurs, ce travail met en lumière l'importance d'une démarche continue de formation des acteurs du secteur et d'adaptation des modèles aux évolutions économiques. Il souligne également la nécessité de construire un cadre de référence solide, fondé sur des données fiables, pour soutenir une prise de décision éclairée et responsable.

Valeur estimée du projet : 3 500 000 Ariary. Ce montant reflète l'investissement et les ressources nécessaires pour développer, déployer et maintenir la plateforme de prédiction du risque de crédit présentée dans ce mémoire.

En somme, ce projet offre une contribution concrète à l'amélioration des pratiques de gestion du risque de crédit, et ouvre la voie à des recherches futures portant sur l'optimisation, l'interprétabilité et l'intégration opérationnelle des modèles d'intelligence artificielle dans le secteur bancaire.

À l'avenir, il serait pertinent d'explorer l'intégration de données alternatives (comportementales, textuelles, etc.) ainsi que l'automatisation de la mise à jour des modèles en temps réel, afin de renforcer la précision et la robustesse des systèmes de décision.

Références

- [1] Artemis Courtage. <https://www.artemiscourtage.com>, 2024. Consulté le : 14 juin 2025.
- [2] DataBlist. <https://github.com/datablist/sample-csv-files>, 2024. Consulté le : 14 juin 2025.
- [3] Federal Reserve Bank of St. Louis. <https://fred.stlouisfed.org>, 2024. Consulté le : 14 juin 2025.
- [4] International Monetary Fund. <https://www.imf.org>, 2021. IMF Publications. Consulté le : 14 juin 2025.
- [5] International Monetary Fund. <https://data.imf.org>, 2024. Consulté le : 14 juin 2025.
- [6] LendingClub. <https://www.lendingclub.com/info/download-data.action>, 2018. Consulté le : 14 juin 2025.
- [7] Hamadi Matoussi and Aida Krichène Abdelmoula. La prévention du risque de défaut dans les banques tunisiennes. *HAL Open Science*, 2010. Consulté le : 14 juin 2025.
- [8] Microfinance Data (Mix Market Archive). <https://microdata.worldbank.org>, 2020. Consulté le : 14 juin 2025.
- [9] OpenML. <https://www.openml.org/search?type=data&status=any&id=43743>, 2024. Consulté le : 14 juin 2025.
- [10] John Smith, Li Zhao, and Karim Ahmed. Determinants of loan approval : Evidence from lending practices. *Journal of Financial Services Research*, 2020.
- [11] UCI Machine Learning Repository. <https://archive.ics.uci.edu/ml/index.php>, 2024. Consulté le : 14 juin 2025.
- [12] World Bank. <https://data.worldbank.org>, 2024. Consulté le : 14 juin 2025.

Cours suivis :

- Dr RAMASONDRANO Andriamanjaka : Python pour la Data, apprentissage supervisé et non supervisé
- Mme RAKOTONDRABARY Elihary : Introduction à l’IA et arbres de décision appliqués à la théorie des graphes

9 ANNEXES




FIGURE 59 – Boxplot de ID

Le boxplot de ID montre une distribution relativement centrée avec quelques valeurs extrêmes, signalant des enregistrements uniques qui pourraient nécessiter une vérification pour des anomalies.




FIGURE 60 – Boxplot de Status

Le boxplot de Status montre une faible variabilité, indiquant que la majorité des cas sont concentrés autour de 0, nécessitant une analyse plus approfondie.




FIGURE 61 – Boxplot de Year

Le boxplot de Year indique que les valeurs sont très concentrées autour de 2020, ce qui pourrait nécessiter une attention sur les tendances temporelles et leur impact.




FIGURE 62 – Distribution de ID

Il y a une homogénéité élevée des IDs. Cela peut suggérer que les emprunteurs sont regroupés selon des caractéristiques communes.




FIGURE 63 – Distribution de Status

Il y a une forte concentration à 0, ce qui pourrait indiquer que la majorité des prêts sont accordés à des emprunteurs sans antécédents de défaut.




FIGURE 64 – Distribution de Year

Nous observons une concentration élevée autour de 2019, ce qui pourrait correspondre à une période de forte activité de prêt.